UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INFORMÁTICA



Modelo de aprendizaje automático para la comparación ajustada por riesgo del desempeño hospitalario en Chile

Informe de Seminario

Estudiante: Felipe Ignacio Baeza Muñoz

Carrera: Ingeniería de Ejecución en Computación e Informática

Profesor guía: Manuel Villalobos Cid



Santiago - Chile

3 de agosto de 2026

Resumen

En Chile no existe un mecanismo público que permita evaluar el desempeño clínico de los hospitales de forma ajustada a la complejidad de sus pacientes. Esta ausencia impide distinguir si las variaciones en indicadores parciales, como la mortalidad o los días de hospitalización, operan como señales de alerta sobre el desempeño institucional, o si simplemente reflejan que algunos recintos atienden casos más graves. Aunque estos dos resultados no miden la calidad total de un hospital, sí constituyen métricas esenciales para su evaluación. Sin esta distinción, tanto los gestores del sistema como la ciudadanía carecen de información analítica útil para la toma de decisiones.

El sistema de salud público chileno registra anualmente información detallada de los egresos mediante los Grupos Relacionados por Diagnóstico (GRD). Aprovechando este masivo volumen de datos bajo principios de resguardo, trazabilidad y uso responsable, el proyecto propone una solución informática con tres componentes. Primero, un motor predictivo de aprendizaje automático que resuelve dos problemas distintos: la clasificación del riesgo de mortalidad y la regresión de los días de estancia esperados. Segundo, un algoritmo que genera un indicador ajustado por riesgo al comparar los resultados observados contra las predicciones matemáticas. Tercero, una plataforma web para explorar interactivamente estas métricas. Este sistema no pretende entregar una medición definitiva de la calidad asistencial, sino generar señales estandarizadas para apoyar la mejora de los procesos hospitalarios.

Palabras clave: desempeño hospitalario, ajuste por riesgo, aprendizaje automático, Grupos Relacionados por Diagnóstico, transparencia en salud.

Este documento fue redactado con el apoyo de herramientas de inteligencia artificial, utilizadas con fines de corrección ortográfica, síntesis de información y explicación de conceptos.

Tabla de contenidos

1. Introducción **1**

1.1. Contexto 1

1.2. Motivación 1

1.3. Propósito de la solución 2

2. Planteamiento del problema **2**

2.1. Tecnología del estado del arte 2

2.2. Brecha tecnológica 4

2.3. Enunciado del problema 4

3. Objetivos del proyecto **5**

3.1. Objetivo general 5

3.2. Objetivos específicos 5

4. Análisis del enfoque **6**

4.1. Enfoques actuales 6

4.2. Justificación del enfoque seleccionado 6

4.3. Propósito del producto 7

4.4. Impacto ético y social 7

5. Descripción del producto **8**

5.1. Arquitectura y funcionalidades mínimas 8

5.2. Alcance y limitaciones del producto 9

5.3. Descripción de la evaluación del producto 10

6. Metodología, herramientas y ambiente de desarrollo **11**

6.1. Justificación de la metodología a usar 11

6.2. Herramientas de desarrollo 12

6.3. Ambiente de desarrollo 13

7. Plan de trabajo **13**

7.1. Definición de actividades 13

7.2. Carta Gantt 14

Referencias Bibliográficas **15**

Referencias **15**

1. Introducción

1.1. Contexto

Desde una perspectiva informática, el sistema de salud chileno presenta un enorme desafío de procesamiento de datos. De acuerdo con lo expuesto en el informe de Cid et al. (Cid y cols., 2024), el Sistema Nacional de Servicios de Salud (SNSS) atiende al 80 % de la población mediante una red de 188 hospitales distribuidos en 29 Servicios de Salud a lo largo del país. Esta red se organiza en tres niveles de complejidad, según su capacidad resolutiva y las especialidades disponibles. En conjunto, estos establecimientos generan cada año más de un millón de egresos hospitalarios, cada uno con información clínica detallada.

Como política pública para financiar esta actividad asistencial, el Ministerio de Salud (MINSAL) y FONASA impulsaron la adopción del sistema de Grupos Relacionados por Diagnóstico (GRD), introducido en Chile a partir de 2001 (Cid y cols., 2024; Zapata, 2018). Este sistema de codificación clasifica cada egreso en grupos con perfil clínico similar, asignándole de forma estática una categoría base de severidad y un nivel general de riesgo de mortalidad. Aunque el estándar GRD provee estos insumos con fines principalmente administrativos, el verdadero desafío analítico radica en extraer y procesar estas variables pre-codificadas para convertirlas en estimaciones predictivas de riesgo. Al año 2023, 68 establecimientos operaban bajo el esquema GRD, con proyección de alcanzar 80 hospitales hacia 2026 (Cid y cols., 2024).

Sin embargo, la ausencia de herramientas de análisis de datos impide aprovechar esta información de forma dinámica. La Ley 20.285 de Transparencia garantiza el acceso a estos registros (Congreso Nacional de Chile, 2008), lo que ha permitido obtener formalmente desde FONASA una base de datos granular y anonimizada con millones de egresos históricos. A pesar de esta disponibilidad, actualmente plataformas oficiales como el Departamento de Estadísticas e Información de Salud (DEIS) publican activamente solo promedios brutos (como la tasa de mortalidad general o estancia media) sin ajuste por la gravedad de los pacientes atendidos. Por otro lado, las métricas que sí intentan evaluar eficiencia, como las elaboradas por la DIPRES (Dirección de Presupuestos (DIPRES), 2021), permanecen encapsuladas en informes técnicos estáticos.

1.2. Motivación

El contexto descrito muestra que Chile cuenta con una red hospitalaria que registra datos clínicos masivos de forma sistemática. Sin embargo, estudios recientes sobre este mecanismo Cid y cols. (2024) señalan que el sistema GRD se utiliza principalmente para financiamiento, mientras que su uso analítico es aún incipiente. Lo que falta en el ecosistema actual no es la recolección de datos, sino un flujo informático reproducible que calcule los resultados clínicos esperados, los agregue a nivel de hospital y permita comparar objetivamente el desempeño de las distintas instituciones.

Desde el punto de vista de la informática, la motivación principal radica en resolver la brecha

tecnológica de transformar este volumen crudo de datos tabulares en predicciones individuales y visualizaciones interpretables. La Comisión Nacional de Productividad (2020) documenta diferencias significativas en la eficiencia de los hospitales públicos que podrían no explicarse únicamente por la gravedad de sus pacientes. Si bien estas diferencias pueden estar influenciadas por los recursos o el tamaño de cada recinto, también indican que existen variaciones en cómo gestionan internamente la atención de sus pacientes. Para identificar objetivamente estas señales, se requiere un mecanismo computacional que estime el resultado clínico esperado para cada paciente y lo compare con el resultado efectivamente observado.

1.3. Propósito de la solución

El propósito de este proyecto es desarrollar un modelo analítico que procese los perfiles clínicos de los pacientes para estimar resultados esperados específicos, tales como la mortalidad intrahospitalaria y los días de estadía. A partir de estas estimaciones, el sistema calculará indicadores estandarizados de desempeño hospitalario que podrán ser consultados a través de un prototipo de plataforma web.

El núcleo del sistema es un motor predictivo que calculará los valores esperados para cada paciente basándose exclusivamente en sus características clínicas y demográficas. Con estas predicciones individuales agregadas a nivel institucional, el sistema generará el índice de razón Observado/Esperado (O/E) en dos métricas separadas: la razón de muertes observadas sobre muertes esperadas, y la razón de días de estadía observados sobre los esperados. Esta métrica no constituye una medición absoluta de la calidad asistencial, sino una herramienta de información inicial que actúa como señal de alerta objetiva, ayudando a los gestores de salud a identificar qué procesos internos requieren revisión o mejora.

Finalmente, los resultados de este modelo se presentarán en un prototipo de plataforma web de carácter académico y demostrativo. Este prototipo se conceptualiza como una herramienta orientada exclusivamente a la transparencia hacia la ciudadanía mediante la exploración interactiva de perfiles clínicos. En este entorno, los usuarios podrán ingresar sus datos y visualizar las métricas de desempeño hospitalario ajustado de forma clara y fácil de interpretar.

2. Planteamiento del problema

2.1. Tecnología del estado del arte

Evaluación de la eficiencia hospitalaria. Para comparar hospitales de forma justa es necesario considerar que no todos atienden el mismo tipo de pacientes. Un hospital que recibe casos más graves tendrá naturalmente más muertes y estadías más largas, sin que eso signifique necesariamente peor atención. Para resolver ese problema, la literatura ha adoptado los Grupos Relacionados por Diagnóstico (GRD) como herramienta estándar de ajuste. Chen y cols. (2023) muestran, a partir de 29 estudios con más de 36 millones de pacientes, que los indicadores basados en GRD permiten una comparación más ajustada por casuística.

Zapata (2018) confirma que, bien calculados, esos indicadores son válidos para evaluar desempeño institucional.

Métodos tradicionales de ajuste por riesgo. Históricamente, los primeros análisis de mortalidad por GRD se basaban en estadística descriptiva básica, como lo demuestra el trabajo de Ramos Rincón y cols. (2001), evidenciando las limitaciones de usar tasas de mortalidad sin ajuste multivariado. Posteriormente, el enfoque estándar adoptado para predecir riesgo fue la regresión logística, que calcula el resultado esperado para cada paciente. Aunque la regresión logística sigue siendo una línea base predictiva muy sólida y ampliamente utilizada, puede perder capacidad si no se modelan manualmente las interacciones complejas que ocurren cuando los pacientes presentan múltiples diagnósticos y comorbilidades combinadas.

Enfoques de aprendizaje automático para datos estructurados. Si bien existen estudios que aplican aprendizaje profundo (*deep learning*) a historiales médicos complejos (Rajkomar y cols., 2018), los registros hospitalarios GRD se organizan de manera tabular con variables categóricas y numéricas bien definidas. En este tipo de información estructurada, la literatura avala el uso de ensambles de árboles de decisión (como *Random Forest* o *Gradient Boosting*). Es importante separar la evidencia según el resultado analizado: para la estimación de días de estadía (un problema de regresión continua), estos algoritmos han demostrado alta capacidad para minimizar el error predictivo (Mekhaldi y cols., 2020; Almeida y cols., 2024); por otro lado, para predecir la mortalidad intrahospitalaria (un problema de clasificación binaria), la literatura confirma su solidez al modelar el riesgo clínico en pacientes complejos (Zeleke y cols., 2023; Guzmán-Muñoz y cols., 2025). Esta ventaja radica en la capacidad intrínseca de los árboles para capturar relaciones no lineales e interacciones de forma automática. La Tabla 1 detalla el propósito de los estudios revisados.

Programas nacionales de indicadores ajustados por riesgo (HSMR/SHMI). Los antecedentes más directos de este proyecto son los programas nacionales de indicadores estandarizados de mortalidad hospitalaria implementados en Europa: el *Hospital Standardised Mortality Ratio* (HSMR), adoptado en los Países Bajos y Canadá, y el *Summary Hospital-level Mortality Indicator* (SHMI), publicado anualmente por el NHS de Inglaterra. Ambos calculan una razón O/E mediante modelos de regresión ajustados por características del paciente al ingreso y publican sus resultados para todos los hospitales del sistema. La literatura crítica de estos programas (Shahian y cols., 2010) documenta los modos de falla conocidos: sobredispersión estadística en los límites de control, sesgo de alta anticipada y aversión a casos graves como respuestas institucionales a la publicación de indicadores. Conocer estos antecedentes justifica las decisiones metodológicas adoptadas en la presente propuesta: corrección de sobredispersión en *funnel plots*, declaración explícita del sesgo de alta anticipada como limitación no corregible con datos administrativos, y rediseño del módulo ciudadano para eliminar la función de comparación institucional directa.

Tabla 1: Comparación de estudios seleccionados según su propósito analítico.

Estudio	**Método principal**	**Variable**	**Resultado**	**Propósito analítico**
Chen y cols. (2023)	Meta-análisis GRD	Estancia / Muerte	Baja estancia, riesgo estable	Impacto de implementación
Ramos Rincón y cols. (2001)	Estadística básica	Mortalidad	Tasas brutas limitadas	Limitaciones sin ajuste
Rajkomar y cols. (2018)	*Deep learning*	Mortalidad	AUROC 0,93	Predicción individual
Mekhaldi y cols. (2020)	*Gradient Boosting*	Estancia	Alto ajuste en regresión	Predicción individual
Guzmán-Muñoz y cols. (2025)	Estadística tradicional	Mortalidad	Riesgo en Chile	Ajuste por riesgo

2.2. Brecha tecnológica

La brecha que aborda este proyecto no es exclusivamente tecnológica, sino también metodológica: radica en la falta de una arquitectura analítica que automatice el procesamiento de datos médicos y estandarice su interpretación. Para aprovechar verdaderamente estos registros en la evaluación del desempeño, se requiere un ecosistema de software continuo que integre un **modelo predictivo** capaz de estimar el riesgo clínico de cada paciente, un motor de cálculo que transforme estas estimaciones en un **indicador ajustado** institucional, y una **plataforma web** que despliegue estos resultados de forma interactiva. Lo que falta es precisamente la integración funcional de estos tres elementos, resolviendo de forma concurrente los desafíos metodológicos de cómo definir el ajuste, cómo validar estadísticamente los algoritmos, cómo agregar los resultados y cómo presentarlos para evitar interpretaciones erróneas, logrando así pasar del dato administrativo en bruto a una verdadera transparencia sanitaria.

2.3. Enunciado del problema

A pesar de que el sistema de salud recopila diariamente datos tabulares GRD sobre cada egreso hospitalario, actualmente no existe una solución pública, automatizada y ajustada por riesgo a nivel nacional que procese esta información para evaluar desempeño. Desde una perspectiva informática, el problema radica en estructurar un volumen masivo de datos administrativos para alimentar un modelo predictivo, superando restricciones técnicas como la distribución fuertemente sesgada de los días de estadía y el bajo número de

fallecimientos en algunos hospitales. Además, se debe resolver el problema de la causalidad de los datos, garantizando que el algoritmo utilice únicamente las variables conocidas al momento del ingreso y omita cualquier métrica generada al cierre médico que revele el resultado final de forma anticipada. La ausencia de este procesamiento analítico impide la generación sistemática de indicadores que comparen objetivamente la frecuencia de eventos reales frente a los esperados matemáticamente. En consecuencia, los usuarios finales (gestores de salud y ciudadanos) carecen de señales métricas estandarizadas que faciliten el monitoreo de variaciones en los procesos de atención hospitalaria.

3. Objetivos del proyecto

3.1. Objetivo general

Desarrollar un sistema computacional basado en aprendizaje automático que estime resultados clínicos esperados (específicamente, mortalidad intrahospitalaria y días de estadía) y genere indicadores ajustados por riesgo, con el propósito de apoyar la comparación analítica del desempeño entre hospitales de la red pública chilena utilizando registros de Grupos Relacionados por Diagnóstico (GRD).

3.2. Objetivos específicos

1. Estructurar un conjunto de datos clínico-administrativo (cohorte histórica 2019-2024) proveniente de registros GRD, verificando empíricamente la completitud de las variables predictoras clave y la ausencia de valores nulos o atípicos no justificados antes de ingresar a la fase de modelado.

2. Construir el espacio de características (*features*) predictoras a partir de los diagnósticos y comorbilidades de los pacientes, asegurando que el modelo se alimente exclusivamente de variables clínicas basales sin heredar sesgos de índices de riesgo preexistentes.

3. Desarrollar dos modelos predictivos validados temporalmente (entrenados en la cohorte 2019-2023 y probados en 2024) que superen a la línea base de regresión logística en PR AUC (mortalidad) y en RMSE (estadía), alcanzando una calibración verificable con un *Brier Skill Score* mayor a cero (mejor que la prevalencia base), una pendiente de calibración en el rango $[0{,}8; 1{,}2]$ y una razón O/E global en el rango $[0{,}95; 1{,}05]$.

4. Calcular el indicador de desempeño hospitalario ajustado por riesgo (Razón Observado/Esperado) por institución para la cohorte de prueba, validando la significancia estadística de las variaciones mediante la construcción de intervalos de confianza al 95 % y 99,8 % utilizando gráficos de embudo (*funnel plots*).

5. Desplegar un prototipo de plataforma web interactiva que alcance tiempos de latencia menores a 2 segundos en la inferencia de riesgo, permitiendo la visualización de los *funnel plots* institucionales y

procesando perfiles ciudadanos de forma segura, garantizando la nula persistencia de datos personales en el servidor.

4. Análisis del enfoque

4.1. Enfoques actuales

La evaluación del desempeño hospitalario ha evolucionado a lo largo del tiempo buscando neutralizar el sesgo que genera la complejidad de los pacientes. Históricamente, los sistemas de salud han utilizado métricas descriptivas no ajustadas, como tasas de mortalidad y promedios de estadía bruta, como indicadores directos de calidad. Este método inicial es limitado: un hospital que atiende casos más graves mostrará peores cifras sin que ello implique una menor calidad clínica. A pesar de esta deficiencia, el uso de métricas globales sin ajuste de riesgo sigue presente en la gestión operativa diaria y en los tableros estadísticos tradicionales.

Para resolver el problema de la heterogeneidad de los pacientes, el sistema de salud chileno adoptó los Grupos Relacionados por Diagnóstico (GRD). Si bien esta herramienta fue concebida para permitir el análisis de casuística, eficiencia y *benchmarking* institucional, en la práctica local su uso ha estado fuertemente orientado a la contención de costos. Con frecuencia, este sistema opera principalmente como un mecanismo tarifario para calcular las transferencias de presupuesto desde FONASA hacia los hospitales (Cid y cols., 2024; Dirección de Presupuestos (DIPRES), 2021), subutilizando su potencial para publicar de forma activa evaluaciones de desempeño clínico.

Para superar el uso puramente administrativo de los GRD y las limitaciones de las métricas brutas, la investigación reciente ha adoptado modelos predictivos de aprendizaje automático. Estas herramientas pueden mejorar el rendimiento predictivo en ciertos escenarios al detectar relaciones no lineales e interacciones complejas en los datos clínicos, si bien la regresión logística tradicional sigue siendo absolutamente necesaria como línea base metodológica por su robustez en calibración e interpretabilidad. En la literatura actual, enfoques como el aprendizaje profundo (Rajkomar y cols., 2018) y los algoritmos basados en árboles (Mekhaldi y cols., 2020; Zeleke y cols., 2023) han demostrado una alta precisión para predecir la mortalidad y la estadía prolongada. Esta tecnología representa el estado del arte y ofrece la capacidad metodológica necesaria para construir indicadores ajustados que sirvan como señales de alerta temprana, complementando la gestión financiera con una perspectiva clínica analítica.

4.2. Justificación del enfoque seleccionado

El presente proyecto adoptará un modelo de aprendizaje automático seleccionado empíricamente tras comparar múltiples algoritmos. Para ello, se evaluarán métodos tradicionales (regresión logística) frente a modelos basados en ensambles de árboles. La selección final del algoritmo se fundamentará en tres criterios

técnicos: **rendimiento predictivo** (evaluado mediante métricas como PR AUC para clasificación y RMSE/R^2 para regresión), **calibración estadística** (medida mediante el *Brier Score* y curvas de calibración para asegurar que las probabilidades estimadas coincidan con frecuencias reales) y **estabilidad temporal** (comprobada mediante validación en cohortes de años posteriores).

La hipótesis técnica sugiere que los modelos de *Gradient Boosting* podrían superar a la regresión logística tradicional al analizar bases de datos estructuradas; no obstante, su desempeño se determinará de forma estrictamente empírica. Esta expectativa inicial se justifica porque los algoritmos de ensamble son capaces de capturar interacciones no lineales complejas entre el diagnóstico principal y las múltiples comorbilidades del paciente (Mekhaldi y cols., 2020). Finalmente, la compatibilidad de estos modelos con librerías como SHAP (Lundberg y cols., 2020) garantiza que el algoritmo no opere como una "caja negra", permitiendo interpretar la contribución algorítmica aditiva de cada variable clínica en el cálculo del riesgo, si bien debe recalcarse que SHAP entrega una explicación matemática del modelo y no una relación causal biológica definitiva.

4.3. Propósito del producto

Desde una perspectiva metodológica, el objetivo de la solución es netamente **computacional**: diseñar, construir y evaluar un motor predictivo robusto que estime resultados clínicos individuales, y formular un algoritmo que agregue estas predicciones para calcular el indicador ajustado (Observado/Esperado) por hospital. Es fundamental precisar que este indicador funcionará exclusivamente como una señal estadística de desempeño ajustada por riesgo, y no como una medida directa o definitiva de la calidad asistencial.

4.4. Impacto ético y social

El diseño y despliegue de este sistema conlleva un profundo impacto ético y social, generando externalidades que deben ser explícitamente mitigadas. Si bien la plataforma democratiza el acceso a la información sanitaria y fomenta la transparencia (Fung y cols., 2008), su implementación introduce riesgos sistémicos documentados. En primer lugar, la publicación de estos indicadores puede generar incentivos perversos de codificación (*upcoding*): dado que registrar más comorbilidades incrementa el riesgo esperado (y reduce artificialmente el O/E), los hospitales podrían exagerar la gravedad de los pacientes. Como medida de mitigación, la inclusión del Índice de Exhaustividad de Codificación operará no solo como métrica de calidad, sino como herramienta de vigilancia frente a esta práctica.

En segundo lugar, existe el riesgo de selección de pacientes. La publicación de reportes de desempeño tiene el antecedente de inducir aversión al riesgo, donde los centros médicos podrían evitar admitir casos extremadamente graves para proteger sus métricas. Para mitigar esto, los resultados institucionales (O/E) no se presentarán como un ranking lineal, sino mediante gráficos de embudo (*funnel plots*), lo que desincentiva la comparación directa y resalta únicamente a los recintos que escapan significativamente de la variabilidad estadística esperada.

Finalmente, el diseño del explorador ciudadano presentaba una exposición ética considerable: en su formulación original, al mostrar el historial de desempeño de cada hospital frente a un perfil clínico, la plataforma habría funcionado en la práctica como un recomendador de hospitales. Este riesgo fue identificado y abordado como decisión de diseño: el componente de comparación institucional fue eliminado de la funcionalidad ciudadana. El mérito técnico del módulo (inferencia en tiempo real, API, latencia, descomposición SHAP) se preserva mediante una demostración pedagógica que no cruza el perfil del usuario con las métricas institucionales, reconociendo que en el sistema público chileno el paciente no elige hospital y que el desempeño hospitalario correlaciona con recursos territoriales que no son accionables por el ciudadano individual.

5. Descripción del producto

5.1. Arquitectura y funcionalidades mínimas

El producto computacional se estructura en tres capas arquitectónicas interconectadas que conformarán el prototipo inicial:

1. **Capa de Almacenamiento:** Base de datos estructurada que consolida los registros históricos preprocesados y persiste las predicciones calculadas.
2. **Capa de Procesamiento (Motor predictivo y API):** Módulo analítico (*back-end*) encargado de la inferencia algorítmica. El sistema procesará el volumen masivo de datos históricos (aproximadamente 5,8 millones de egresos) e incluirá capacidades de inferencia en tiempo real a través de una API REST. Esta arquitectura permitirá evaluar de manera dinámica el riesgo y la estadía esperada para los perfiles clínicos ingresados por los usuarios en la plataforma web.
3. **Capa de Visualización:** Plataforma web interactiva (*front-end*) que actúa como interfaz gráfica para el usuario final.

Para la primera versión del prototipo web, se han definido las siguientes funcionalidades mínimas, orientadas a perfiles de usuarios de gestión clínica y ciudadanía general:

- Consulta del indicador ajustado (Observado/Esperado) por hospital, presentado mediante gráficos de embudo (*funnel plots*) con límites de control estadístico al 95 % y 99,8 %. Este formato visual desincentiva la interpretación de los resultados como un ranking punitivo, destacando únicamente las variaciones significativas frente al desempeño esperado.
- Aplicación de filtros dinámicos esenciales: búsqueda por año, hospital específico, nivel de complejidad y tipo de resultado (*outcome* de mortalidad o estadía).
- **Demostración pedagógica del motor predictivo:** Formulario donde el usuario ingresa un perfil clínico sintético (diagnósticos y comorbilidades) y el sistema calcula el riesgo estimado en tiempo real,

mostrando la descomposición de variables mediante SHAP. Esta funcionalidad opera como demostrador técnico de la inferencia algorítmica y **no** realiza comparaciones institucionales, en reconocimiento a que en el sistema público chileno el paciente no elige hospital y de que el desempeño hospitalario correlaciona con recursos territoriales que no son accionables por el ciudadano individual.

5.2. Alcance y limitaciones del producto

El alcance del sistema abarcará a los 68 establecimientos de alta y mediana complejidad de la red pública chilena. En términos de acceso, el proyecto procesará una cohorte histórica (2019–2024) obtenida formalmente a través de FONASA vía Ley de Transparencia. Un alcance fundamental respecto a la **ciberseguridad y privacidad** es que los registros fueron entregados de forma estrictamente anonimizada. El modelo algorítmico no requiere, almacena ni procesa información de identificación personal (PII), garantizando que su diseño sea inherentemente compatible con normativas como la Ley Marco de Ciberseguridad y la protección de la privacidad del paciente.

Respecto a las limitaciones del proyecto, la principal es la dependencia absoluta de la calidad de los datos codificados. Para transparentar esto, el sistema calculará un **Índice de Exhaustividad de Codificación** basado en el promedio de comorbilidades registradas por paciente. A esto se suma un riesgo crítico de fuga de información metodológica si los registros de FONASA carecen de marcadores de "diagnóstico presente al ingreso". Si no es posible separar las comorbilidades previas de las complicaciones intrahospitalarias desarrolladas durante la internación, estas últimas ingresarán al modelo como predictoras del propio resultado que causaron, inflando artificialmente el riesgo esperado en los hospitales con mayores tasas de complicaciones. Otra limitación crítica radica en las **diferencias de recursos hospitalarios**: el modelo matemático evalúa exclusivamente el riesgo clínico del paciente según sus diagnósticos, ignorando asimetrías de infraestructura, déficit de especialistas o presupuesto entre los distintos centros médicos. Asimismo, se aplicará un **umbral mínimo de volumen institucional**: los hospitales que no alcancen un número suficiente de egresos anuales en la cohorte de prueba serán excluidos del cálculo del indicador institucional, tanto por inestabilidad estadística como para prevenir la reidentificación indirecta de pacientes al cruzar año, hospital y GRD infrecuente (supresión de celdas pequeñas como control de revelación estadística).

Finalmente, cabe declarar el **sesgo de alta anticipada**, conocido en la literatura como uno de los modos de falla clásicos de los indicadores tipo HSMR (Shahian y cols., 2010). Un hospital puede reducir su tasa de mortalidad intrahospitalaria dando de alta o trasladando pacientes en estado terminal antes de que fallezcan, sin que la calidad de atención haya cambiado. Con datos administrativos anonimizados no es posible corregir este sesgo completamente, pues requeriría vincular los egresos con el Registro Civil para calcular mortalidad a 30 días post-alta, lo que está fuera del alcance de este proyecto.

Por último, cabe destacar una limitación metodológica fundamental: el indicador funciona como un instrumento analítico de orientación estadística, pero no prueba causalidad. Esto significa que un desempeño bajo no debe interpretarse automáticamente como un veredicto definitivo de mala calidad asistencial. La

herramienta computacional no reemplaza las auditorías clínicas en terreno, sino que actúa como una señal de alerta sistemática y priorizada para que los gestores focalicen la revisión de sus procesos internos.

5.3. Descripción de la evaluación del producto

La evaluación del producto se estructurará en tres dimensiones fundamentales: la validación estadística de los modelos predictivos individuales, la robustez matemática del indicador O/E agregado, y la validación funcional de la interfaz web.

En el caso de la predicción de estadía, se tomará la decisión metodológica de entrenar el modelo exclusivamente sobre la población de **sobrevivientes al alta**. Esta decisión responde al riesgo de *outcomes* competitivos: los pacientes fallecidos presentan estadías cortas no por eficiencia hospitalaria, sino por una lógica clínica diferente. Incluirlos confundiría al modelo, que aprendería que los perfiles de alto riesgo de muerte tienen estadías cortas, distorsionando el denominador del O/E de estadía de manera silenciosa. Esta exclusión se documentará explícitamente como una limitación del *outcome*. La estadía de los pacientes fallecidos se reportará como **estadística descriptiva independiente**, pues sigue siendo clínicamente relevante (estadías muy cortas en fallecidos pueden indicar altas anticipadas, y estadías muy largas pueden indicar pacientes en cuidados prolongados), aunque no como parte del indicador O/E. Además, en lugar de aplicar una transformación logarítmica seguida de exponenciación (que sesga la estimación hacia la mediana geométrica en lugar de la media, subestimando sistemáticamente el denominador del O/E), se utilizará directamente una **función objetivo Poisson o Tweedie** dentro de LightGBM/XGBoost, que modela la media de distribuciones de conteo asimétricas sin requerir ningún paso de retransformación. El error se segmentará por grupo GRD como análisis secundario.

Por otro lado, la predicción de mortalidad presenta un desafío estadístico importante debido al desbalance de los datos (la mortalidad observada en la base histórica ronda el 2,78 %). A diferencia de enfoques clásicos, en este proyecto no se utilizarán técnicas de rebalanceo (como SMOTE, submuestreo o *Bootstrapping*) ni ponderación asimétrica de clases. En términos absolutos, el 2,78 % de 5,8 millones de egresos representa más de 160.000 casos positivos, un volumen empírico más que suficiente para entrenar el algoritmo sobre la distribución natural. Más aún, la decisión de no reponderar ni balancear se fundamenta en que cualquier alteración artificial de la distribución sesgaría la priora efectiva, provocando que las probabilidades predichas dejen de coincidir con la incidencia observada. Dado que el cálculo del indicador O/E depende estrictamente de que la suma de predicciones probabilísticas equivalga a las muertes esperadas, es imperativo entrenar sobre la distribución original para mantener la calibración matemática del modelo. A nivel de evaluación, la capacidad de discriminación se medirá mediante el **PR AUC**, reportado como ganancia relativa sobre la línea base de prevalencia (PR AUC base = 2,78 %), lo que hace la métrica directamente interpretable. Complementariamente, se aplicará calibración mediante *Brier Skill Score*, pendiente de calibración e intervalo E/O (Steyerberg y cols., 2010; Van Calster y cols., 2019). Para resolver la potencial circularidad entre la severidad GRD y las variables predictoras, el **modelo principal** se construirá únicamente con variables

clínicas CIE-10 en bruto (comorbilidades Elixhauser), mientras que la severidad GRD se reservará como **variable de análisis de sensibilidad**: si el modelo con severidad GRD no mejora sustancialmente al modelo principal, ello valida que las comorbilidades individuales son suficientemente informativas por sí solas.

Para asegurar la capacidad de generalización del sistema, la estrategia de partición de datos utilizará una validación temporal estricta (Moons y cols., 2015). La partición será anidada: los años 2019-2022 se destinarán al entrenamiento inicial, el año 2023 se reservará como cohorte de **calibración** (para eventual recalibración isotónica o de Platt si el modelo muestra desviación en la pendiente de calibración), y el año 2024 se utilizará como prueba definitiva sin ningún tipo de ajuste posterior. Dado que los años 2020-2021 corresponden al período de pandemia COVID-19 (aproximadamente el 40 % del período de entrenamiento), se realizará un **análisis de sensibilidad excluyendo esos dos años** para verificar que el modelo no esté sesgado por la estructura anómala de mortalidad y ocupación hospitalaria de ese período. Asimismo, se dejará definido el plan en caso de que la regresión logística supere empíricamente al modelo de ensamble: en ese escenario, el modelo final será la regresión logística, documentando la comparación mediante curvas de calibración superpuestas y tamaño de efecto, no por significancia estadística (que con 5,8 millones de registros sería siempre significativa aunque la diferencia sea trivial).

Respecto al cálculo del indicador O/E institucional, la aplicación directa de límites binomiales a los *funnel plots* producirá, con 5,8 millones de egresos y 68 hospitales, una **sobredispersión** que marcaría a la mayoría de los recintos como "atípicos" por mero efecto del tamaño muestral. Para evitar que la herramienta pierda credibilidad desde la primera demostración, se implementará la **corrección de Spiegelhalter** (Spiegelhalter, 2005): en vez de asumir que toda la variación entre hospitales es error de muestreo puro, esta corrección estima la variación adicional real entre instituciones y ensancha los límites del embudo en proporción a esa variabilidad estructural. El resultado son límites al 95 % y 99,8 % que sólo destacan hospitales con variaciones genuinamente inusuales, no simplemente grandes.

Finalmente, la evaluación de la interfaz web se definirá mediante criterios mínimos funcionales y de usuario: la consistencia absoluta de los datos (confirmando que los tableros reflejen exactamente las respuestas de la API REST), la latencia y tiempos de respuesta bajo carga moderada, la correcta comprensión de las visualizaciones gráficas, y el éxito en la ejecución de tareas de usuario clave mediante pruebas con perfiles representativos (ej. gestores en salud) (Fung y cols., 2008).

6. Metodología, herramientas y ambiente de desarrollo

6.1. Justificación de la metodología a usar

El desarrollo del proyecto se rige bajo la metodología **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), un estándar metodológico consolidado para la ejecución de proyectos de ciencia de datos (Schröer y cols., 2021). Su ciclo iterativo, que abarca desde la comprensión del problema hasta el despliegue tecnológico, se adapta perfectamente a la naturaleza exploratoria de este trabajo. Aunque

metodologías ágiles como Scrum o Kanban pueden apoyar el desarrollo concurrente de la plataforma web, CRISP-DM provee el marco estructurado indispensable para gestionar bases clínico-administrativas (GRD). Esta necesidad surge por las dependencias estrictas del proyecto, dado que resulta imposible entrenar modelos algorítmicos sin antes procesar matemáticamente la información o limpiar los datos sin comprender su significado clínico. Además, este marco estructurado otorga la flexibilidad de retroceder de fase si los resultados empíricos no cumplen las expectativas.

Para desarrollar el proyecto de forma ordenada, el trabajo se divide en seis etapas principales, cada una directamente vinculada a los objetivos específicos:

1. **Comprensión del dominio:** Definición del problema analítico y estudio de las particularidades clínico-administrativas del sistema GRD.

2. **Comprensión de los datos:** Exploración estadística enfocada en identificar anomalías, lógicas de codificación y el desbalance empírico de la mortalidad. En esta fase se verificará si la base de FONASA incluye el marcador de "diagnóstico presente al ingreso" (POA — *Present on Admission*). Si el marcador no está disponible, se aplicará una **lista blanca CIE-10 bajo el estándar Elixhauser**, que por diseño excluye las complicaciones agudas intrahospitalarias, resolviendo de raíz el riesgo de fuga de causalidad hacia atrás.

3. **Preparación de datos:** Depuración y estandarización. Se aplicarán criterios de exclusión sobre episodios que no corresponden a hospitalización aguda evaluable: neonatos sanos (GRD de tipo MDC 15 sin patología), episodios obstétricos sin complicación, traslados entrantes (el resultado final del paciente dependerá del hospital receptor, no del emisor), estadías de cero días y GRD no agrupables. Asimismo, se excluirán los procedimientos quirúrgicos como variables predictoras: siendo eventos que ocurren *durante* la hospitalización, no son conocidos al ingreso y su inclusión introduciría fuga de información causal hacia el modelo. Toda imputación se ejecutará estrictamente dentro de los flujos de entrenamiento.

4. **Modelado:** Construcción de dos motores algorítmicos independientes (regresión para estadías y clasificación probabilística para mortalidad), evaluando ensambles de árboles de decisión.

5. **Evaluación:** Medición predictiva y calibración estadística mediante una estricta validación temporal (aislando un año de prueba definitivo), incluyendo segmentaciones por hospital.

6. **Despliegue:** Integración del motor analítico validado en un prototipo web, permitiendo la evaluación dinámica de perfiles ingresados por el usuario y contrastando los resultados con los registros históricos anonimizados.

6.2. Herramientas de desarrollo

La arquitectura tecnológica del proyecto se divide en tres áreas principales: análisis de datos, almacenamiento y visualización web.

Para el procesamiento y modelado predictivo, se utiliza el lenguaje Python debido a su amplio ecosistema para la ciencia de datos. Dada la magnitud de la cohorte histórica (5,8 millones de egresos), el preprocesamiento de registros se apoyará en librerías optimizadas como Polars o estrategias de procesamiento por lotes (*batch*), complementando a herramientas como Pandas y NumPy. Para el entrenamiento algorítmico, se utilizarán implementaciones nativas de *XGBoost* y *LightGBM*, orquestadas mediante el marco de trabajo de *scikit-learn*. Asimismo, se incorpora la librería SHAP para analizar las decisiones del sistema y garantizar la interpretabilidad clínica (Lundberg y cols., 2020).

En cuanto a la arquitectura de *backend*, PostgreSQL funcionará como el motor de base de datos para almacenar primordialmente los indicadores agregados O/E y resultados consolidados a nivel hospitalario. La interfaz de comunicación (*API REST*) se construirá utilizando *FastAPI*, framework seleccionado por su eficiencia en la transferencia asíncrona de datos. Finalmente, el *frontend* interactivo será desarrollado con Vue.js, garantizando que los ciudadanos puedan explorar los resultados clínicos y evaluar perfiles de forma interactiva y sencilla.

6.3. Ambiente de desarrollo

Para garantizar la eficiencia técnica, el desarrollo y entrenamiento analítico se lleva a cabo en una estación de trabajo equipada con un procesador Intel Core i5 de 13ª generación (12 núcleos) y 16 GB de memoria RAM. Aunque el equipo cuenta con una unidad gráfica NVIDIA GeForce RTX 2050, el modelamiento de datos tabulares mediante ensambles (*trees*) aprovechará primordialmente la paralelización multi-hilo del CPU para asegurar estabilidad. Todo el desarrollo se ejecuta sobre el sistema operativo Linux (Ubuntu).

Con el fin de asegurar que la investigación sea reproducible y evitar conflictos entre librerías, el control de dependencias se gestionará mediante archivos de requerimientos estrictos (`requirements.txt`). Posteriormente, los componentes del sistema (*backend* y *frontend*) se encapsularán utilizando contenedores Docker (Merkel, 2014). Para mantener la trazabilidad algorítmica y de la infraestructura, el control de versiones se coordina mediante Git y se aloja en GitHub. Esta estructura metodológica asegura un entorno estandarizado y preparado para un despliegue controlado del prototipo.

7. Plan de trabajo

7.1. Definición de actividades

El desarrollo técnico del proyecto se organiza en una secuencia de actividades basadas en las seis fases de CRISP-DM. Dado que el estudio inicial del problema y la investigación teórica ya se abordaron en este informe, la planificación inicia directamente con la construcción del sistema informático. El flujo de trabajo comienza con la configuración del entorno y el diseño de la arquitectura, avanza hacia la preparación de los datos y el entrenamiento de los modelos matemáticos, y concluye con la evaluación estadística y el

despliegue de la plataforma web.

7.2. Carta Gantt

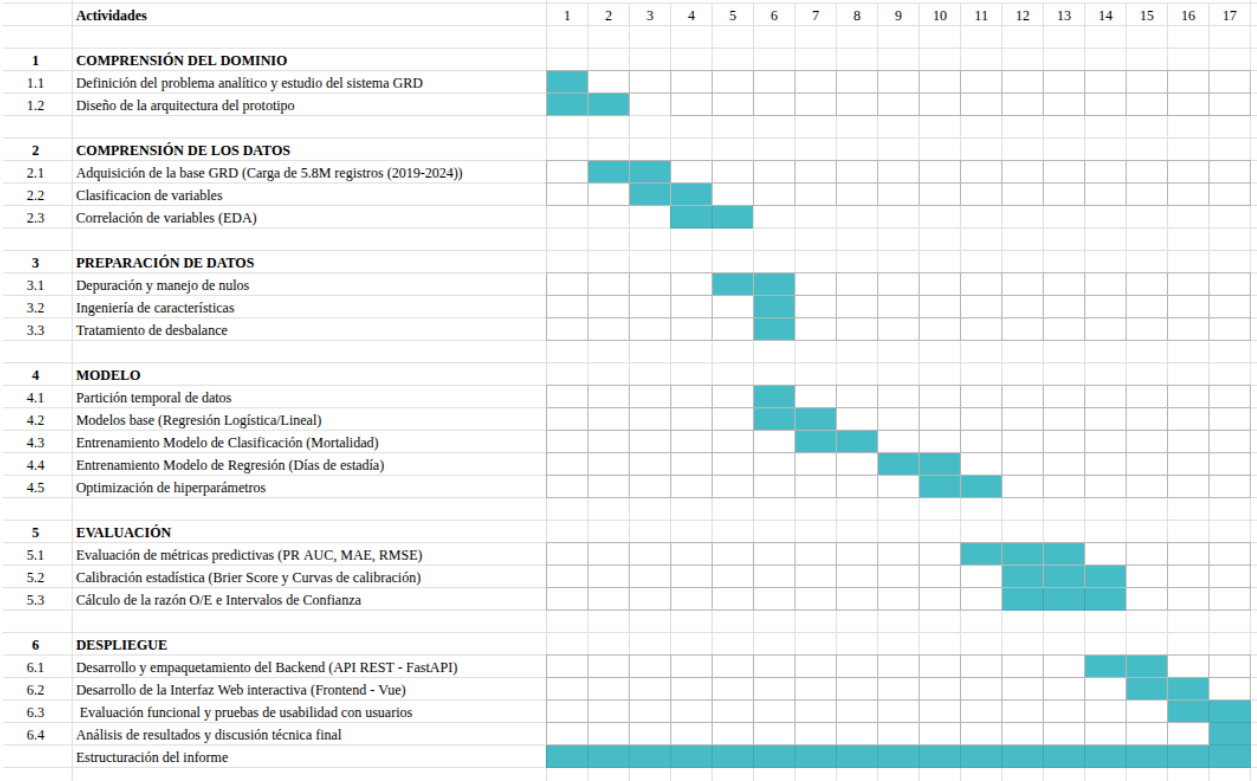


Figura 1: Planificación del proyecto mediante Carta Gantt.

Referencias

Almeida, R., Viana, J., y Pereira, J. (2024). Hospital length-of-stay prediction using machine learning algorithms—A literature review. *Applied Sciences*, *14*(3), 1–25. doi: 10.3390/app14031231

Chen, Y., Cryan, C., Yu, K., Bhatt, D., y Bhatt, J. (2023). Impact of Diagnosis-Related Group–Based payment on inpatient quality of health care: A systematic review and meta-analysis. *INQUIRY: The Journal of Health Care Organization, Provision, and Financing*, *60*, 1–16. doi: 10.1177/00469580231167011

Cid, C., Dawson, N., Medina, C., Espinoza, A., y Bastías, G. (2024). Lecciones y desafíos del uso de los Grupos Relacionados por el Diagnóstico en Chile. *Revista Panamericana de Salud Pública*, *48*, e67. doi: 10.26633/RPSP.2024.67

Comisión Nacional de Productividad. (2020). *Uso eficiente de quirófanos electivos y gestión de lista de espera quirúrgica no GES* (Inf. Téc.). Santiago, Chile: Comisión Nacional de Productividad, Gobierno de Chile.

Congreso Nacional de Chile. (2008). *Ley 20.285 — sobre acceso a la información pública.* `https://www.bcn.cl/leychile/navegar?idNorma=276363`. (Última versión: 11-JUL-2025)

Dirección de Presupuestos (DIPRES). (2021). *Evaluación de la eficiencia hospitalaria: indicadores de mortalidad y estancia por GRD* (Inf. Téc.). Santiago, Chile: Dirección de Presupuestos, Ministerio de Hacienda, Gobierno de Chile.

Fung, C. H., Lim, Y.-W., Mattke, S., Damberg, C., y Shekelle, P. G. (2008). Systematic review: the evidence that publishing patient care performance data improves quality of care. *Annals of Internal Medicine*, *148*(2), 111–123. doi: 10.7326/0003-4819-148-2-200801150-00006

Guzmán-Muñoz, E., Concha-Cisternas, Y., Lira, C., y Valdés-Badilla, P. (2025). In-hospital mortality among 40,253 older adults with hip fracture: Survival outcomes in a Chilean cohort. *Journal of Clinical Medicine*, *14*, 7717. doi: 10.3390/jcm14247717

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., ... Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, *2*, 56–67. doi: 10.1038/s42256-019-0138-9

Mekhaldi, R. N., Caulier, P., Dammak, R., Lecron, F., y Fohr, P. (2020). Using machine learning models to predict the length of stay in a hospital setting. *Advances in Intelligent Systems and Computing*, *1159*, 202–211. doi: 10.1007/978-3-030-45688-7_21

Merkel, D. (2014). Docker: Lightweight Linux containers for consistent development and deployment. *Linux Journal*, *2014*(239), 2. Descargado de `https://www.linuxjournal.com/content/docker-lightweight-linux-containers-consistent-development-and-deployment`

Moons, K. G. M., Altman, D. G., Reitsma, J. B., Ioannidis, J. P. A., Macaskill, P., Steyerberg, E. W., ... Collins, G. S. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): explanation and elaboration. *Annals of Internal Medicine*, *162*(1), W1–W73. doi: 10.7326/M14-0698

Rajkomar, A., Oren, E., Chen, K., Dai, A. M., Hajaj, N., Hardt, M., ... Dean, J. (2018). Scalable and accurate deep learning with electronic health records. *npj Digital Medicine*, *1*(18). doi: 10.1038/s41746-018-0029-1

Ramos Rincón, J. M., García Ruipérez, D., Aliaga Matas, F., Lozano Cutillas, D., y Llanos Llanos, R. (2001). Tasas específicas de mortalidad por GRD y diagnóstico principal según CIE-9-MC. *Anales de Medicina Interna*, *18*(10), 510–516.

Schröer, C., Kruse, F., y Marx Gómez, J. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science*, *181*, 526–534. doi: 10.1016/j.procs.2021.01.199

Shahian, D. M., Wolf, R. E., Iezzoni, L. I., Kirle, L., y Normand, S.-L. T. (2010). Variability in the measurement of hospital-wide mortality rates. *New England Journal of Medicine*, *363*(26), 2530–2539. doi: 10.1056/NEJMsa1006396

Spiegelhalter, D. J. (2005). Funnel plots for comparing institutional performance. *Statistics in Medicine*, *24*(8), 1185–1202. doi: 10.1002/sim.1970

Steyerberg, E. W., Vickers, A. J., Cook, N. R., Gerds, T., Gonen, M., Obuchowski, N., ... Kattan, M. W. (2010). Assessing the performance of prediction models: a framework for traditional and novel measures. *Epidemiology*, *21*(1), 128. doi: 10.1097/EDE.0b013e3181c30fb2

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., y Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, *17*(1), 230. doi: 10.1186/s12916-019-1466-7

Zapata, M. (2018). Importancia del sistema GRD para alcanzar la eficiencia hospitalaria. *Revista Médica Clínica Las Condes*, *29*(3), 347–352. doi: 10.1016/j.rmclc.2018.04.004

Zeleke, A. J., Palumbo, P., Tubertini, P., Miglio, R., y Chiari, L. (2023). Machine learning-based prediction of hospital prolonged length of stay admission at emergency department: a Gradient Boosting algorithm analysis. *Frontiers in Artificial Intelligence*, *6*. doi: 10.3389/frai.2023.1179226