

UNIVERSIDAD DE SANTIAGO DE CHILE

Facultad de Ingeniería — Departamento de Ingeniería Informática

Documento de Planificación del Desarrollo
Fase 1: Comprensión del Dominio

*Proyecto de Tesis: Sistema de evaluación del desempeño hospitalario
ajustado por riesgo mediante aprendizaje automático*

Estudiante: Felipe Ignacio Baeza Muñoz

Profesor guía: Manuel Villalobos Cid

Carrera: Ingeniería de Ejecución en Computación e Informática

Septiembre 2026

1. Descripción del problema

El sistema de salud público chileno registra todos los egresos hospitalarios mediante el sistema de Grupos Relacionados por Diagnóstico (GRD). Cada vez que un paciente es dado de alta, trasladado o fallece en un hospital público, se genera un registro con información clínica detallada: diagnósticos, días de hospitalización, resultado, entre otros. En conjunto, estos registros suman más de un millón de egresos al año.

A pesar de la disponibilidad de estos datos, las plataformas oficiales publican únicamente indicadores brutos: tasas de mortalidad generales y promedios de días de estadía sin ningún ajuste por la gravedad de los pacientes atendidos. Esto impide comparar hospitales de forma justa, ya que un centro que atiende casos clínicamente más complejos mostrará peores cifras independiente de la calidad de su atención.

El proyecto propone construir un sistema computacional que procese los registros GRD históricos (2019–2024) para estimar, mediante modelos de aprendizaje automático, los resultados esperados de cada hospital dado el perfil de complejidad de sus pacientes. Al comparar lo esperado con lo observado, se genera un indicador ajustado por riesgo que permite una evaluación más objetiva del desempeño hospitalario.

2. Fuente de datos

Los datos provienen de una solicitud formal a FONASA realizada mediante la Ley 20.285 de Transparencia. Se recibieron seis archivos de texto (uno por año, de 2019 a 2024) que contienen los registros de egresos hospitalarios de la red pública chilena.

Característica	Detalle
Fuente	FONASA — Ley 20.285 de Transparencia
Período cubierto	Egresos hospitalarios 2019 – 2024
Volumen total	5.808.536 registros de egresos
Columnas por registro	129 variables clínicas y administrativas
Formato de entrega	Archivos de texto plano separados por barra vertical (), uno por año
Privacidad	Datos completamente anonimizados — sin RUT, nombre ni datos de contacto
Nota especial	En 2019 una columna fue renombrada en años posteriores; el sistema lo gestiona automáticamente

3. Objetivo del modelo

El sistema construirá dos modelos predictivos independientes utilizando los registros históricos:

- **Modelo de mortalidad (clasificación):** Predice la probabilidad de que un paciente fallezca durante su hospitalización.

- **Modelo de estadía (regresión):** Predice cuántos días debería estar hospitalizado un paciente según su perfil clínico.

Con las predicciones de ambos modelos se calculará el indicador Razón Observado/Esperado (O/E) por hospital: la cantidad de eventos reales dividida por la cantidad de eventos que el modelo esperaba. Este indicador permite identificar hospitales con resultados significativamente distintos de lo esperado, presentando los resultados en gráficos estadísticos que evitan interpretaciones simplistas.

El sistema no pretende rankear hospitales ni señalar responsables. Su función es generar señales de alerta objetivas para que los gestores hospitalarios puedan identificar procesos internos que requieren revisión.

4. Regla fundamental: solo información disponible al ingreso

El modelo únicamente puede utilizar información que existe en el momento en que el paciente llega al hospital. Usar datos que solo existen después del ingreso equivale a que el modelo ya conozca el resultado antes de predecirlo, lo cual invalida completamente cualquier conclusión.

Variables que sí puede usar el modelo:

- Sexo del paciente
- Edad al momento del ingreso
- Tipo de ingreso (urgencia o programado)
- Contexto de llegada (desde domicilio, derivado de otro hospital, programado)
- Diagnóstico principal de ingreso
- Enfermedades crónicas previas registradas en los diagnósticos secundarios
- Mes de ingreso y si fue en fin de semana
- Historial de hospitalizaciones previas del mismo paciente en los últimos 12 meses

Variables explícitamente excluidas del modelo:

- Procedimientos quirúrgicos realizados durante la hospitalización (30 columnas) — ocurren después del ingreso
- Uso de pabellón quirúrgico — ocurre después del ingreso
- Código del hospital — causaría que el modelo evalúe el historial del establecimiento en lugar del riesgo del paciente
- Riesgo de mortalidad precalculado por el sistema GRD — usarlo sería copiar un resultado ya existente
- Tipo de alta — es exactamente el resultado que el modelo debe predecir

5. Estructura del procesamiento de datos

El procesamiento se organiza en capas secuenciales. Cada capa toma como entrada la capa anterior y aplica un conjunto definido de transformaciones:

Capa	Descripción
Capa Cruda	Los archivos originales de FONASA. No se modifican nunca.
Capa Bronce	Los datos son leídos exactamente como vienen y guardados en un formato optimizado. No se corrige ni transforma nada en esta etapa.
Capa Plata	Los datos se limpian: corrección de formatos de fecha, estandarización de textos, identificación de valores imposibles, y separación de pacientes censurados.
Capa Oro	Se construyen todas las variables que el modelo usará: cálculo de edad, historial del paciente, indicadores de comorbilidades, y clasificación de diagnósticos.
Modelo	Entrenamiento de los dos modelos predictivos sobre los datos de la capa oro.
Indicador O/E	Cálculo del indicador ajustado por riesgo para cada hospital.
Plataforma web	Visualización interactiva de los resultados.

6. Ajuste por enfermedades previas del paciente (Índice de Elixhauser)

El componente más importante del ajuste por riesgo es la medición de las enfermedades crónicas que el paciente ya tenía antes de ingresar al hospital. Estas enfermedades afectan directamente el riesgo de morir o de requerir una hospitalización más larga, independiente del hospital donde se atiende el paciente.

Para medir esto se utilizará el Índice de Elixhauser (Quan et al., 2005), que es el estándar internacional más utilizado para este propósito. El índice clasifica las enfermedades crónicas en 31 categorías a partir de los diagnósticos secundarios registrados en cada egreso. Para cada categoría se genera una variable binaria (1 si el paciente tiene esa condición, 0 si no la tiene), resultando en 31 variables independientes.

Se utilizan 31 variables separadas en lugar de un índice único para que el modelo pueda detectar interacciones entre enfermedades. Por ejemplo, el riesgo de un paciente con diabetes e insuficiencia renal no es la suma de los dos riesgos por separado; la combinación tiene un efecto diferente que solo las 31 variables separadas permiten capturar.

Las 31 categorías incluyen: insuficiencia cardíaca, arritmias, valvulopatía, hipertensión, diabetes (con y sin complicación), enfermedad pulmonar crónica, insuficiencia renal, enfermedad hepática, cáncer (metastásico y sin metástasis), VIH/SIDA, obesidad, coagulopatía, depresión, psicosis, abuso de alcohol, abuso de drogas, entre otras.

Una limitación reconocida es que los datos de FONASA no incluyen un marcador que distinga si una enfermedad ya existía antes del ingreso o si apareció durante la hospitalización. Para mitigar esto, se utilizará la lista blanca del estándar Elixhauser, que excluye por diseño las condiciones con mayor probabilidad de ser complicaciones desarrolladas dentro del hospital. Esta limitación queda declarada en el informe final.

7. Validación del modelo: partición temporal de los datos

Para verificar que el modelo realmente predice y no simplemente memoriza los datos históricos, se utilizará una partición temporal estricta:

Período	Rol	Uso
2019 - 2022	Entrenamiento	El modelo aprende los patrones clínicos
2023	Calibración	Se verifica si las probabilidades predichas son realistas y se corrigen si es necesario
2024	Prueba definitiva	El modelo se evalúa sobre datos que nunca vio durante el entrenamiento

Los años 2020 y 2021 corresponden al período de la pandemia COVID-19. Dado que la pandemia alteró significativamente los patrones de mortalidad y ocupación hospitalaria, se realizará un análisis adicional excluyendo esos dos años para verificar que el modelo no esté condicionado por ese período excepcional.

8. Criterios de aceptación del modelo

El modelo se considerará válido si supera los siguientes umbrales al evaluarlo sobre los datos del año 2024:

Criterio	Umbral	Significado
Discriminación (mortalidad)	PR AUC mayor que la línea base de regresión logística	Mide si el modelo distingue bien quién muere y quién sobrevive
Error de predicción (estadía)	RMSE menor que la línea base de regresión logística	Mide qué tan lejos están las predicciones de los días reales
Calibración estadística	Brier Skill Score mayor que cero	Mide si las probabilidades del modelo son creíbles
Precisión de probabilidades	Pendiente de calibración entre 0.8 y 1.2	Mide si la magnitud de las probabilidades es correcta
Razón O/E global	Entre 0.95 y 1.05	Verifica que el modelo no sobre ni subestime sistemáticamente

9. Limitaciones reconocidas del sistema

- El indicador O/E no es una medida de calidad asistencial. Es una señal estadística que indica dónde revisar, no un veredicto.
- El sistema no puede corregir el sesgo de alta anticipada: si un hospital traslada pacientes en estado terminal antes de que fallezcan, esas muertes no quedan registradas en sus datos. Esta limitación existe en todos los sistemas similares del mundo.
- El modelo no considera las diferencias de infraestructura, presupuesto o dotación de personal entre hospitales.
- La ausencia del marcador POA (diagnóstico presente al ingreso) en los datos chilenos introduce un riesgo residual de contaminación en las comorbilidades, mitigado con la lista blanca Elixhauser.
- Los hospitales con muy pocos egresos en el año de prueba quedarán excluidos del indicador por inestabilidad estadística.

10. Propuestas que requieren aprobación del profesor guía

Las siguientes decisiones metodológicas están planteadas como propuestas. Requieren validación del profesor guía antes de proceder con su implementación.

Propuesta	Descripción	Resolución del profesor
Seguimiento longitudinal del paciente	Utilizar el identificador encriptado del paciente para calcular cuántas veces fue hospitalizado en los últimos 12 meses y cuántos días pasaron desde su última hospitalización. Estas variables se incluirían como predictores del modelo.	Aprobado / Rechazado / Pendiente revisión
Variables condicionales de contexto institucional	Tres variables requieren verificación empírica antes de decidir si se incluyen en el modelo: el servicio de ingreso (UCI/UTI), la especialidad médica tratante, y si el paciente fue derivado desde otro hospital. Si el análisis muestra que estas variables reflejan capacidad instalada del hospital más que gravedad del paciente, serán excluidas.	Aprobado / Rechazado / Pendiente revisión
Análisis de equidad (variables socioeconómicas)	Se propone guardar variables como etnia, previsión FONASA, nacionalidad y nivel de privación comunal para un análisis posterior que verifique si el sistema genera resultados distintos según características socioeconómicas de los pacientes. Estas variables NO entrarían al modelo predictivo principal.	Aprobado / Rechazado / Pendiente revisión
Exclusión de ETNIA como variable del modelo	La variable de etnia del paciente NO se incluirá como predictor del modelo ni como variable de análisis en esta tesis, reconociendo la complejidad metodológica que implicaría su interpretación correcta. Solo se registra su existencia en los datos.	Aprobado / Rechazado / Pendiente revisión
Análisis de sensibilidad COVID-19	Se propone repetir el entrenamiento del modelo excluyendo los años 2020 y 2021 para verificar si los patrones aprendidos cambian significativamente. Este análisis se reportaría como hallazgo complementario, no como resultado principal.	Aprobado / Rechazado / Pendiente revisión

