UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INFORMÁTICA

INFORME TÉCNICO — FASE 1
COMPRENSIÓN DEL DOMINIO

Proyecto de Tesis

Sistema de evaluación del desempeño hospitalario ajustado por riesgo mediante aprendizaje automático

Estudiante	Felipe Ignacio Baeza Muñoz
Profesor guía	Manuel Villalobos Cid
Carrera	Ingeniería de Ejecución en Computación e Informática
Fecha	Octubre 2026

1. Qué es el proyecto y por qué importa

En Chile, cada vez que un paciente sale de un hospital público se genera un registro clínico y administrativo que se clasifica con el sistema de Grupos Relacionados por Diagnóstico (GRD). Cada registro trae diagnósticos, procedimientos, días de hospitalización y cómo terminó el episodio. En total son más de un millón de egresos al año (Cid et al., 2024).

El problema es que hoy no existe un indicador público que compare hospitales ajustando por qué tan graves son sus pacientes. Las plataformas oficiales publican promedios brutos de mortalidad y de días de estadía. Un hospital que recibe pacientes más graves va a mostrar más muertes y estadías más largas aunque trabaje igual de bien que otro. Por eso, comparar tasas brutas no dice nada claro sobre la calidad. Existen métricas de eficiencia elaboradas por DIPRES y por la Comisión Nacional de Productividad, pero quedan en informes estáticos y no en un indicador público y reproducible.

> **Propósito central.** El sistema no busca hacer rankings punitivos ni señalar culpables. Busca entregar una señal estadística objetiva que indique dónde puede haber una desviación relevante respecto de lo esperado.

Para lograrlo, el proyecto construye un sistema con cuatro partes:

- **Procesamiento de datos.** Se trabaja con 5.808.536 egresos (2019–2024) que FONASA entregó mediante la Ley 20.285 de Transparencia.
- **Modelos predictivos.** Dos modelos de aprendizaje automático estiman cuántas muertes y cuántos días de estadía se esperan según el perfil clínico de los pacientes de cada hospital.
- **Indicador O/E.** Se compara lo observado con lo esperado y se obtiene la razón Observado/Esperado por hospital.
- **Plataforma web.** Muestra los indicadores por hospital y una demo pedagógica del modelo.

2. Quiénes lo van a usar

Grupo	Qué necesita	Qué le da el sistema
Gestores de hospitales y Servicios de Salud	Saber si su hospital se aleja de lo esperado, para decidir qué procesos revisar.	Razón O/E de mortalidad y de estadía, con gráficos de embudo.
MINSAL, FONASA y DIPRES	Una señal estandarizada para priorizar revisiones y asignar recursos.	Los mismos indicadores, con un método documentado y reproducible.
Ciudadanía	Entender cómo funciona un modelo de riesgo y cómo se ve la transparencia en salud.	Una demo pedagógica con un perfil clínico sintético. No compara hospitales.

3. Objetivos y criterios de éxito

3.1 Objetivo del proyecto

Que gestores y autoridades tengan una señal estadística objetiva, comparable entre hospitales y justa con la gravedad de los pacientes, para orientar revisiones internas. Para eso se construyen dos modelos predictivos, un indicador O/E por hospital con gráficos de embudo y un prototipo web.

3.2 Criterios de éxito del proyecto (no son del modelo)

Estos criterios miden si el sistema sirve y es seguro de usar. Los criterios del modelo están en la sección 12.

Criterio	Cómo se mide	Meta
Respuesta rápida	Tiempo de respuesta de la inferencia en la demo, con carga moderada.	Menos de 2 segundos.
Privacidad	Revisión del código, de la base de datos y de los registros del servidor.	Ningún dato personal guardado en ninguna parte.
Consistencia	Comparar lo que muestra el tablero con lo que devuelve la API.	Coinciden en todo.
Comprensión	Pruebas con usuarios representativos, es decir, gestores en salud, sobre la interpretación de los gráficos y las tareas clave.	La lista de tareas y la proporción mínima de éxito se definen antes de la prueba, con el profesor guía.
Uso responsable	Revisión de las funciones de la plataforma.	No hay ranking lineal ni recomendación de hospitales.
Reproducibilidad	Ejecutar todo el proceso desde los archivos originales.	Se regeneran los mismos resultados.

4. Fuente de datos

Fuente	FONASA, mediante la Ley 20.285 de Transparencia
Período	Egresos hospitalarios 2019 a 2024
Volumen	5.808.536 registros
Columnas por registro	129 variables clínicas y administrativas
Formato de entrega	Archivos de texto separados por barra vertical, uno por año
Privacidad	Sin RUT, nombre ni datos de contacto. Ojo: sí traen fechas exactas de nacimiento, ingreso y alta (ver sección 14).
Nota sobre 2019	La columna CIP_ENCRIPTADO se llamaba ID_BENEFICIARIO en el primer año. El código lo maneja solo.

5. Reglas del modelo

Hay siete reglas (R1 a R7) que ninguna decisión de implementación puede romper. Cada una dice también qué pasaría si se rompe.

5.1 Las ocho reglas

N.º	Regla	Qué dice	Qué pasa si se viola
R1	Nada que revele el desenlace	El modelo no puede usar datos que se generan durante la hospitalización y que dependen de cómo le fue al paciente: procedimientos, cirugías, medicamentos, fecha de alta y severidad del GRD. Hay una excepción declarada: los diagnósticos (ver más abajo).	El modelo aprendería con información que no existe al momento de predecir. Los resultados serían buenos en el papel e inútiles en la práctica.
R2	El hospital no puede ser predictor	El código del hospital, el Servicio de Salud y cualquier variable que identifique o describa al establecimiento están prohibidos como predictores.	El modelo aprendería la historia de cada hospital y no el riesgo del paciente. El O/E mediría si el modelo reconoce hospitales, no su desempeño.
R3	Las enfermedades previas son el núcleo del ajuste	Las 31 categorías de Elixhauser se calculan solo con los diagnósticos secundarios, nunca con el principal, y todas están en el modelo principal.	Sin ajustar por enfermedades previas, los hospitales con pacientes más complejos parecerían siempre peores.
R4	Los datos originales de FONASA son inmutables	Los archivos originales nunca se modifican. Todo se procesa en capas y, después de la ingesta, el código tiene prohibido volver a leerlos.	Se perdería la posibilidad de rastrear errores al origen y el proceso dejaría de ser reproducible.
R5	Los errores se anulan, no se imputan en la limpieza	Si un valor es imposible, se anula solo ese valor y se documenta. No se reemplaza por un promedio ni por otro valor calculado. Los faltantes se tratan después, en el modelado (sección 10.3).	Imputar mete suposiciones que pueden distorsionar los resultados. Un valor real siempre es mejor que uno estimado.
R6	Validación sobre datos que el modelo nunca vio	El rendimiento se mide solo con el año 2024, que no se usa en ninguna etapa del entrenamiento ni de la calibración.	Las métricas saldrían demasiado optimistas y no reflejarían el desempeño ante casos nuevos.
R7	Los fallecidos no entrenan el modelo de estadía	El modelo de días de hospitalización se entrena solo con sobrevivientes. Los fallecidos se conservan para estadísticas descriptivas.	Los fallecidos tienen estadías cortas porque murieron, no por eficiencia. El modelo aprendería que los pacientes graves se van rápido y distorsionaría el O/E de estadía.

> **Lo que hay que tener presente.** Los diagnósticos son la excepción. FONASA entrega el diagnóstico principal y los secundarios tal como se codificaron al egreso, y no trae el marcador

> que dice si un diagnóstico ya existía al ingresar. O sea, no es información cien por ciento conocida al ingreso. La usamos igual porque es la forma estándar de ajustar por riesgo con datos administrativos y porque sin ella no hay ajuste posible.

Para cuidar ese riesgo hacemos cuatro cosas:

- De los diagnósticos secundarios solo se usan las 31 categorías del índice de Elixhauser.
- No se usa el riesgo de mortalidad del GRD ni procedimientos. La severidad del GRD solo entra en un análisis de sensibilidad aparte.
- Se hace un análisis de sensibilidad sin las categorías más propensas a ser complicaciones (sección 8).
- Se declara como limitación en el informe final.

5.2 Las ocho categorías de las columnas

Cada una de las 129 columnas cae en una de estas categorías. Solo una entra al modelo.

Categoría	¿Entra al modelo?	Qué significa
FEATURE_BASAL	Sí	Datos que se conocen cuando el paciente llega: edad, sexo, forma de ingreso y antecedentes clínicos. Los diagnósticos entran con reserva (R1).
TARGET	No: es lo que se predice	Si el paciente falleció y cuántos días estuvo internado. El modelo aprende de estos resultados, pero nunca los usa como predictor.
FUENTE_DERIVADA	No: se transforma	Datos crudos que se convierten en otra variable. La fecha de nacimiento sirve para calcular la edad y luego se borra.
FILTRO_COHORTE	No: solo define quién se analiza	Sirve para incluir o excluir pacientes. El código GRD saca a los recién nacidos sanos y a los partos normales, y el tipo de alta y la marca de traslado sacan los episodios sin desenlace comparable.
LLAVE_AGREGACION	No: solo organiza resultados	Código del hospital, Servicio de Salud y año. Se usan al final para agrupar el O/E por establecimiento.
PROHIBIDA_FUGA	No: daría la respuesta	Datos que se generan durante la hospitalización o al alta, y el riesgo de mortalidad del GRD.
DESCARTAR	No: sin información útil	Columnas vacías en todos los años o con contenido que no corresponde a ningún código. Incluye la columna con valores con estructura de RUT.

5.3 Estado de las variables clave

Variable	Categoría	Nota
Edad, sexo, mes, día de la semana, fin de semana y forma de ingreso	FEATURE_BASAL	Se conocen al ingresar. En la Fase 2 se confirma qué columnas traen el sexo y la forma de ingreso.
Diagnóstico principal en dos niveles y 31 indicadores de Elixhauser	FEATURE_BASAL, con reserva	Se codifican al egreso. Ver R1.
Hospitalizaciones en los últimos 12 meses y días desde el egreso previo	FEATURE_BASAL, pendiente de aprobación	Se calculan en Oro, pero no entran al modelo hasta que el profesor guía responda.
Servicio de ingreso	FEATURE_BASAL, condicional	En la Fase 2 se confirma qué registra. Si es la unidad donde estuvo el paciente durante la hospitalización, se descarta y pasa a PROHIBIDA_FUGA.
Especialidad médica y paciente derivado	FEATURE_BASAL, condicional	Se revisa si reflejan la gravedad del paciente o la capacidad del hospital. Si es lo segundo, se sacan.
Procedimientos, cirugías, fechas de intervención, medicamentos y fecha de alta	PROHIBIDA_FUGA	Ocurren durante la hospitalización o al alta.
IR_29301_MORTALIDAD	PROHIBIDA_FUGA	Prohibida siempre, tampoco en sensibilidad (R6).
Severidad del GRD	PROHIBIDA_FUGA en el modelo principal	Solo se usa en un análisis de sensibilidad aparte.
Código GRD	FILTRO_COHORTE	Solo se usa para excluir pacientes.
Código del hospital, Servicio de Salud y año	LLAVE_AGREGACION	Solo para agrupar resultados (R2).
Fecha de nacimiento exacta	FUENTE_DERIVADA	Se usa para la edad y después se borra.
Mortalidad y estadía	TARGET	Son los resultados a predecir.
Columnas vacías o sin contenido válido	DESCARTAR	Incluye la columna con valores con estructura de RUT.

6. Arquitectura de procesamiento por capas

El procesamiento tiene capas secuenciales. Cada capa parte de la anterior y ninguna vuelve atrás.

Capa	Formato	Qué contiene y qué garantiza
Cruda	Archivos .txt originales de FONASA	Los 6 archivos originales. No se modifican y son la única fuente de verdad. Después de la ingesta el código tiene prohibido volver a leerlos. No es una capa de procesamiento. Como contiene el valor sensible (sección 14), queda con acceso restringido, no se copia y no se sube a GitHub.
Bronce	Parquet, por año de archivo	Datos leídos tal como vienen, todo como texto. La columna sensible se descarta aquí sin guardar su contenido. Las filas que no se pueden leer se guardan aparte con su número de línea y el motivo. Garantía: filas leídas más filas rechazadas es igual al total de líneas del archivo.
Plata	Parquet, por año de egreso	Datos limpios y estandarizados: fechas convertidas, texto normalizado, valores imposibles anulados y episodios censurados identificados. Garantía: ningún episodio desaparece sin quedar documentado.
Oro	Parquet	Variables finales para el modelo: edad, variables de historial, indicadores de Elixhauser y diagnóstico en dos niveles. La fecha de nacimiento se borra al calcular la edad. Garantía: ninguna variable prohibida está presente.
Base de datos	PostgreSQL	Solo guarda el catálogo de hospitales, con los años en que cada uno trabaja con GRD y su nivel de complejidad, y los resultados agregados. Ningún registro de paciente.

7. Etapas del pipeline

Etapa 1: validar el esquema

Antes de procesar nada se verifica que cada archivo tenga exactamente las 129 columnas esperadas, con los nombres correctos. Si falta una, el proceso se detiene e indica cuál. Si aparece una desconocida, también se detiene hasta decidir qué hacer con ella.

Etapa 2: ingesta y datos sensibles (Capa Bronce)

Los 6 archivos se convierten a Parquet y se leen sin corregir nada. Como los datos de FONASA no traen un identificador por registro, el sistema crea el ID_EPISODIO a partir del año del archivo, el número de línea y una huella digital del contenido de la fila. Si se procesa el mismo archivo dos veces, cada fila recibe el mismo identificador.

En esta misma etapa se revisan todas las columnas buscando valores con estructura de identificador personal. Si aparece alguno, se aísla sin guardarlo en ningún registro, solo se anota cuántos hay y en qué columna, y la columna se descarta.

Etapa 3: limpieza y estandarización (Capa Plata)

- Conversión de fechas a un formato único (los archivos usan dos).

- Corrección del separador decimal (coma en vez de punto).
- Unificación de la categoría OTRO de la etnia, que viene escrita de dos formas distintas. Se hace aunque la etnia no entre al modelo.
- Normalización de diagnósticos: mayúsculas, sin tildes, sin puntos internos y sin espacios extra.
- Anulación selectiva de valores imposibles: se anula solo el valor malo y el episodio se conserva.
- Identificación de episodios censurados: los traslados a otro hospital quedan marcados con desenlace desconocido.
- Revisión de filas repetidas y de episodios del mismo paciente con las mismas fechas. Se documenta cuántos hay antes de decidir qué hacer.
- Conteo de datos faltantes por variable y por año.

Etapa 4: ingeniería de características (Capa Oro)

Se construyen las variables del modelo. El sistema mantiene la lista de variables prohibidas y, si alguna aparece entre los predictores, el proceso se detiene con un mensaje de error explícito.

Variable	Qué mide	Fuente	Estado
EDAD_ANIOS	Edad exacta al ingreso	FECHA_NACIMIENTO y FECHA_INGRESO	Permitida
MES_INGRESO, ES_FIN_SEMANA	Mes del ingreso y si fue sábado o domingo	FECHA_INGRESO	Permitida
N_EGRESOS_12M	Hospitalizaciones del paciente en los últimos 12 meses	CIP_ENCRIPTADO e historial	Pendiente de aprobación
DIAS_DESDE_EGRESO_PREVIO	Días desde la última hospitalización	CIP_ENCRIPTADO e historial	Pendiente de aprobación
HISTORIAL_INCOMPLETO	Marca los episodios de 2019 cuya ventana de 12 meses cae antes del inicio de los datos	Fecha de ingreso	Pendiente de aprobación
CIE10_3C	Primeros 3 caracteres del diagnóstico principal	DIAGNOSTICO1	Permitida con reserva
GRUPO_CLINICO	Categoría amplia del diagnóstico principal	DIAGNOSTICO1	Permitida con reserva
ELIX_01 a ELIX_31	31 indicadores de enfermedades crónicas previas	DIAGNOSTICO2 a DIAGNOSTICO35	Permitida con reserva
PUNTAJE_VAN_WALRAVEN	Puntaje ponderado que resume el nivel total de comorbilidad	ELIX_01 a ELIX_31	Permitida con reserva

Variable	Qué mide	Fuente	Estado
N_DX_SECUNDARIOS	Cantidad de diagnósticos secundarios registrados	DIAGNOSTICO2 a DIAGNOSTICO35	Solo para el índice de exhaustividad. No es predictor.
MORTALIDAD_BINARIA	Si el paciente falleció (1) o sobrevivió (0)	TIPOALTA	Resultado a predecir
ESTANCIA	Días de hospitalización	FECHAALTA menos FECHA_INGRESO	Resultado a predecir

Sobre el diagnóstico principal. Tiene más de 9.500 códigos distintos y muchos tienen muy pocos casos. Si se usaran todos, el modelo no aprendería bien. Si se usaran solo categorías amplias, se perdería información clínica. Por eso se usan dos niveles: una categoría amplia y un código de 3 caracteres.

Sobre el historial del paciente. Antes de calcularlo hay que comprobar en la Fase 2 que el identificador encriptado sea el mismo en todos los años, porque cambió de nombre en 2019. Además, los pacientes de 2019 no tienen datos previos, así que su historial sale artificialmente corto. Por eso existe la marca HISTORIAL_INCOMPLETO, y se revisa su efecto en el análisis de sensibilidad. Si el identificador no es consistente, se descartan estas variables.

8. El índice de Elixhauser: el ajuste clave

La parte más importante del ajuste por riesgo es medir las enfermedades que el paciente ya tenía. Para eso se usa el índice de Elixhauser, en la versión para códigos CIE-10 (Elixhauser et al., 1998; Quan et al., 2005). El sistema recorre hasta 34 diagnósticos secundarios por paciente y marca con 1 o 0 cuáles de las 31 categorías están presentes. Se calcula solo con los diagnósticos secundarios, nunca con el principal, que es el motivo del ingreso.

Grupo	Categorías
Cardiovasculares	Insuficiencia cardíaca, arritmias, valvulopatía, trastornos de la circulación pulmonar, enfermedad vascular periférica, hipertensión no complicada e hipertensión complicada
Neurológicas	Parálisis y otros trastornos neurológicos
Respiratorias	Enfermedad pulmonar crónica
Metabólicas y endocrinas	Diabetes sin complicación, diabetes con complicación, hipotiroidismo, obesidad, trastornos de líquidos y electrolitos, pérdida de peso
Renales y hepáticas	Insuficiencia renal, enfermedad hepática, úlcera péptica
Oncológicas	Linfoma, cáncer metastásico, tumor sólido sin metástasis
Hematológicas	Coagulopatía, anemia por pérdida de sangre, anemia por deficiencia

Grupo	Categorías
Psiquiátricas y otras	VIH/SIDA, artritis reumatoide, abuso de alcohol, abuso de drogas, psicosis, depresión

8.1 Por qué 31 variables y no un índice único

El riesgo de combinar dos enfermedades no es la suma de los riesgos por separado. Con variables independientes, los modelos basados en árboles pueden descubrir esas combinaciones solos. Un índice único las esconde.

9. Definición de la cohorte

9.1 Qué población se analiza

- Hospitales. Entran los que operaban con GRD en cada año. La lista por año se arma en la Fase 2 a partir de los datos y se guarda en el catálogo de PostgreSQL. Cada hospital se compara solo en los años en que estaba en GRD. Además, en la Fase 2 se cuenta cuántos hospitales distintos aparecen y se compara con los al menos 72 hospitales identificados en los registros históricos de 2019 a 2024 (68 bajo esquema activo de financiamiento GRD en 2023); si la cifra difiere, se ajusta el alcance. Los códigos se contrastan con un catálogo oficial (DEIS o FONASA), que aporta el nivel de complejidad, un dato que los archivos de FONASA no traen.
- **Edad.** Propuesta: analizar solo adultos, de 18 años o más. Los patrones de mortalidad y estadía en niños son distintos y no conviene mezclarlos. Queda pendiente de aprobación y en la Fase 2 se revisa la distribución de edad.

9.2 Qué hacemos con cada tipo de alta

Tipo de alta	Tratamiento
Fallecido	Mortalidad igual a 1. Entra al modelo de mortalidad y no al de estadía.
Alta médica	Mortalidad igual a 0. Entra a los dos modelos.
Traslado a otro hospital	Censurado por defecto. Sale del entrenamiento y del cálculo del O/E. Se propone rastrear al paciente para conocer su desenlace final (sección 9.4).
Traslado entrante (llega desde otro hospital)	Se marca y se conserva en los datos, pero no entra a los modelos ni al O/E.
Otros tipos que aparezcan	En la Fase 2 se listan todos los valores de TIPOALTA y se decide cada uno. Regla por defecto: si no se puede confirmar que el paciente sobrevivió, se trata como censurado.

9.3 Cascada de exclusiones

El sistema genera un reporte de la cascada completa, en el estilo CONSORT, y verifica que ningún paciente desaparezca sin quedar documentado.

Exclusión	Volumen estimado	Por qué
GRD no asignable	215 en muestra de desarrollo; proyectado a ~5.073 en población histórica completa.	Sin GRD válido no es factible clasificar la casuística clínica del egreso.
Recién nacidos sanos (MDC 15)	7.760 en muestra de desarrollo; proyectado a ~146.928 en población histórica completa.	Corresponde a neonatología fisiológica postparto y no a morbilidad aguda. Distorsionaría artificialmente el O/E de recintos materno-infantiles.
Partos normales sin complicación (MDC 14)	19.899 en muestra de desarrollo (2019-2023); proyectado a ~431.832 en población histórica completa.	Eventos obstétricos sin complicación con mortalidad basal nula y estadía protocolizada.
Traslados salientes	~89.438 casos históricos (censurados).	Desenlace intrahospitalario desconocido; su exclusión previene el sesgo de alta anticipada.
Traslados entrantes	Por medir en la Fase 2	Se marcan y se conservan en los datos, pero salen de los modelos y del O/E. El episodio refleja solo la segunda parte de la hospitalización y la misma persona quedaría contada dos veces.
Tipos de alta sin desenlace confirmado	Por medir en la Fase 2	Sin desenlace no se puede evaluar la mortalidad.
Estadías de 0 días	Variable por año	Se excluyen solo del modelo de estadía. Se conservan en el de mortalidad.
Hospitales bajo el volumen mínimo	Por definir	Su indicador es muy inestable (sección 11.3).

9.4 Cómo tratamos los traslados

Con el identificador encriptado se busca si el paciente reapareció en otro hospital poco después. Si aparece, su desenlace final es el del último episodio de esa cadena y el traslado deja de estar censurado. Los que no se logran rastrear siguen censurados. La ventana de días se define en la Fase 2 mirando solo los datos de 2019 a 2022. Esto depende de que el identificador sea

consistente entre años y no elimina el sesgo por completo. Queda por decidir a qué hospital se atribuye ese desenlace: la propuesta es atribuirlo al hospital que trasladó, porque eso es lo que reduce el sesgo de alta anticipada. Todo esto está pendiente de aprobación (sección 20).

10. Modelos predictivos

10.1 Modelo de mortalidad (clasificación)

Predice la probabilidad de que un paciente fallezca durante su hospitalización. Se entrena solo con episodios de desenlace conocido.

Se comparan tres algoritmos: regresión logística (la línea base), LightGBM y XGBoost (Ke et al., 2017; Chen y Guestrin, 2016). La elección se hace con tres criterios: qué tan bien separa a quienes mueren de quienes sobreviven (PR AUC), qué tan realistas son las probabilidades (Brier Score y curvas de calibración) y qué tan estable es en años posteriores. No damos por hecho que gana el modelo más complejo. Si la logística rinde igual o mejor, ese es el modelo final. En ese caso la comparación se documenta con curvas de calibración superpuestas y tamaño del efecto, no con significancia estadística, porque con millones de registros casi cualquier diferencia sale significativa.

No se rebalancean las clases ni se ponderan. El indicador O/E suma las probabilidades predichas y las compara con las muertes reales. Si alteramos la proporción de muertes al entrenar, esa suma deja de coincidir con la realidad y el indicador se desarma. La base completa tiene más de 160.000 muertes, así que hay datos de sobra para entrenar con la distribución natural (Steyerberg et al., 2010; Van Calster et al., 2019).

10.2 Modelo de estadía (regresión)

Predice cuántos días debería estar hospitalizado un paciente según su perfil. Se entrena solo con sobrevivientes, porque los fallecidos tienen estadías cortas por haber muerto y no por eficiencia, y eso le enseñaría al modelo algo falso. La estadía de los fallecidos se reporta aparte como estadística descriptiva.

Se usan LightGBM y XGBoost con objetivo Poisson o Tweedie. Esto modela el promedio directamente. La alternativa de pasar a logaritmo y volver con exponencial subestima el promedio, y eso distorsionaría el denominador del O/E.

10.3 Partición temporal

Período	Rol	Descripción
2019 a 2022	Entrenamiento	El modelo aprende los patrones asociados al riesgo.
2023	Calibración	Se verifica si las probabilidades son realistas. Si la pendiente de calibración sale del rango, se recalibra con método isotónico o de Platt.
2024	Prueba definitiva	Se usa una sola vez, sin ajustes posteriores. Es el único resultado que se reporta (Moons et al., 2015).

11 Definición O/E

- **O/E de mortalidad** de un hospital: muertes observadas en 2024 divididas por la suma de las probabilidades de muerte que el modelo predijo para sus pacientes.
- **O/E de estadía** de un hospital: días de estadía observados divididos por la suma de los días esperados, solo con sobrevivientes.

Un valor de 1,0 significa que el hospital está dentro de lo esperado. Sobre 1,0 significa más eventos de los esperados y bajo 1,0 significa menos. Se calcula por hospital para el año de prueba, 2024.

11.1 Gráficos de embudo y corrección de sobredispersión

Cada hospital se dibuja como un punto según su volumen, junto con límites de control al 95 % y al 99,8 %. Los hospitales dentro de los límites tienen variaciones que el azar puede explicar.

Con millones de egresos, si asumimos que toda la variación entre hospitales es azar de muestreo, casi todos saldrían marcados como atípicos. Por eso se aplica la corrección de Spiegelhalter (2005): estima cuánta variación extra real hay entre hospitales y ensancha los límites en esa medida. Así solo se destacan los hospitales con variaciones realmente inusuales.

11.2 Volumen mínimo por hospital

El umbral se fija antes de mirar los resultados, para no elegirlo a conveniencia. Propuesta inicial: un hospital entra al indicador de mortalidad si en 2024 tiene al menos 500 egresos analizables y al menos 10 muertes esperadas. Además, no se publica ninguna cifra basada en menos de 10 casos, para evitar que se pueda reidentificar a un paciente. Ambos números quedan pendientes de aprobación.

11.3 Índice de exhaustividad de codificación

Mide qué tan completa es la documentación de enfermedades en cada hospital. Para cada paciente se compara cuántas enfermedades se registraron con cuántas se esperarían según su diagnóstico principal y su edad, y después se resume por hospital. Los códigos de factores sociales y de embarazo normal no cuentan. Sirve para dos cosas: mostrar qué tan completa es la codificación y vigilar el upcoding, que es exagerar la gravedad de los pacientes. Cuantas más enfermedades se registran, más riesgo esperado hay y más baja artificialmente el O/E. Se muestra junto al O/E y no entra al modelo. El modelo simple que da el número esperado se define en la Fase 3.

11.4 Qué no es este indicador

Es una señal estadística de desempeño ajustada por riesgo. No es una medida directa de la calidad asistencial, no prueba causalidad y no reemplaza las auditorías clínicas. Tampoco se presenta como ranking.

12. Criterios de aceptación del modelo

El modelo se considera válido si cumple lo siguiente sobre 2024, un año que nunca vio durante el entrenamiento. La última columna dice qué hacemos si algo no se cumple, para no improvisar después.

Criterio	Métrica y umbral	Qué garantiza	Si no se cumple
Discriminación de mortalidad	PR AUC mayor que el de la regresión logística. Se reporta como ganancia relativa sobre la prevalencia de la cohorte final y como diferencia con la logística.	Distingue a quienes mueren de quienes sobreviven. Se usa PR AUC porque la mortalidad es poco frecuente.	El modelo final es la regresión logística.
Error de estadía	RMSE menor que el de la regresión lineal y la regresión Poisson.	Los días predichos son más precisos que los de un modelo simple.	El modelo final es la línea base.
Calibración	Brier Skill Score mayor que cero.	Las probabilidades son realistas y mejores que usar solo la prevalencia.	Se recalibra con 2023. Si sigue sin cumplirse, no se usa el modelo para el indicador y se revisan las variables.
Pendiente de calibración	Entre 0,8 y 1,2.	La magnitud de las probabilidades es correcta, no solo su orden.	Se recalibra con 2023. Si no alcanza, se reporta la desviación y se analiza el efecto de la pandemia.
O/E global de mortalidad	Entre 0,95 y 1,05.	El modelo no sobreestima ni subestima las muertes del conjunto.	Mismo tratamiento que la pendiente de calibración.
O/E global de estadía	Entre 0,95 y 1,05. Propuesta nueva, igual a la de mortalidad.	Los días esperados no están sesgados en el conjunto.	Se revisa la regla de estadías largas y el objetivo Poisson o Tweedie.
Gráficos de embudo	Límites al 95 % y 99,8 % con corrección de sobredispersión.	Separa variaciones reales de las que explica el azar.	No es pasa o no pasa. Si casi todos los hospitales quedan marcados, se revisa la corrección y la calibración.

13. Impacto ético y social

Publicar indicadores de hospitales tiene riesgos conocidos (Fung et al., 2008; Shahian et al., 2010). Los reconocemos y los mitigamos desde el diseño.

- **Upcoding.** Si registrar más enfermedades baja el O/E, los hospitales podrían exagerar la gravedad. La mitigación es el índice de exhaustividad, que lo hace visible.
- **Selección de pacientes.** Publicar resultados puede llevar a evitar a los pacientes más graves. Por eso no hay ranking lineal. Se usan gráficos de embudo, que solo destacan a quienes se salen de lo esperado.
- **Alta anticipada.** Un hospital puede bajar su mortalidad dando de alta o trasladando a pacientes terminales. Con datos administrativos esto no se corrige del todo. Lo declaramos y mostramos la tasa de traslados.

- **Diferencias de recursos.** El modelo mide el riesgo clínico del paciente. No considera infraestructura, presupuesto ni dotación de personal.

13.1 El módulo para la ciudadanía

En el diseño original, la demo cruzaba el perfil que ingresaba el usuario con el desempeño de cada hospital. Eso la convertía en un recomendador de hospitales. Lo eliminamos por dos razones: en el sistema público el paciente no elige hospital, y el desempeño de un hospital depende de recursos del territorio que el ciudadano no puede cambiar.

Lo que queda es una demo pedagógica: el usuario ingresa un perfil clínico sintético, el sistema calcula un riesgo y muestra cuánto aportó cada variable con SHAP (Lundberg et al., 2020). SHAP es una explicación matemática del modelo, no una relación causal biológica. La demo no muestra métricas de hospitales.

Pendiente. Hay que definir con el profesor guía si el prototipo muestra los hospitales con su nombre o solo en un entorno académico.

14. Privacidad y marco legal

14.1 Qué traen los datos

Los datos no traen nombre, RUT ni contacto. Pero sí traen fechas exactas de nacimiento, ingreso y alta. Combinadas con el hospital y el diagnóstico, esas fechas pueden permitir reidentificar a una persona. Por eso no basta con decir que los datos son anónimos y tomamos medidas adicionales.

14.2 Medidas

- La fecha de nacimiento se borra en la Capa Oro, después de calcular la edad.
- La Capa Cruda queda con acceso restringido y fuera de GitHub.
- PostgreSQL y la plataforma web no guardan registros individuales.
- La demo no guarda el perfil que ingresa el usuario, ni en la base ni en los registros del servidor.
- No se publica ninguna cifra basada en menos de 10 casos (propuesta, ver sección 11.3).

14.3 Marco legal

La Ley 20.285 de Transparencia da el acceso a los datos (Congreso Nacional de Chile, 2008). Falta revisar tres cosas:

- Las condiciones de uso de la entrega de FONASA, en especial si permiten publicar resultados por hospital.
- La normativa de datos personales aplicable: la Ley 19.628 y la Ley 21.719. Hay que confirmar cuál está vigente.
- Si la universidad exige que un comité de ética revise el proyecto.

15. Recursos y restricciones

Equipo	Procesador Intel Core i5 de 13.ª generación (12 núcleos), 16 GB de RAM, Linux (Ubuntu).
Tarjeta gráfica	NVIDIA GeForce RTX 2050. No se usa para entrenar: los modelos de árboles sobre datos tabulares aprovechan mejor el procesador.
Datos	Python, Polars, Pandas y NumPy.
Modelado	scikit-learn, LightGBM, XGBoost y SHAP.
Backend y base	FastAPI y PostgreSQL.
Frontend	Vue.js.
Control del entorno	requirements.txt, Docker, Git y GitHub.
Metodología	CRISP-DM (Schröer et al., 2021).

Restricciones.

- **Memoria.** 16 GB son pocos para 5,8 millones de registros con muchas variables. Se trabaja con Parquet, tipos de datos compactos, lectura por lotes y solo las columnas necesarias.
- **Plazo.** El cronograma es apretado (sección 19).
- **Acceso a expertos.** Hoy no hay una persona con perfil clínico revisando las decisiones (sección 17).
- **Datos.** No se pueden compartir ni publicar los archivos originales.

16. Alcance y limitaciones

El sistema no pretende:

- Emitir un dictamen definitivo sobre la calidad clínica de un establecimiento.
- Señalar responsabilidades ni generar rankings.
- Corregir por completo el sesgo de alta anticipada. Para hacerlo habría que vincular los egresos con el Registro Civil y calcular la mortalidad a 30 días después del alta, y eso está fuera del alcance.
- Considerar diferencias de infraestructura, presupuesto o dotación de personal.

El sistema sí pretende:

- Entregar una señal estadística objetiva que oriente revisiones internas y la asignación de recursos.
- Ser reproducible de principio a fin.
- Documentar cada exclusión, decisión y limitación.

Limitaciones que hay que tener presentes:

- Todo depende de la calidad de la codificación de los datos.

- Los diagnósticos no tienen el marcador de presente al ingreso.
- Solo se mide la mortalidad dentro del hospital y los días de estadía, que son parte de la calidad y no toda.
- El indicador no prueba causalidad.
- El resultado se evalúa en un solo año de prueba, 2024.

7. Decisiones pendientes con el profesor guía

N.º	Tema	Qué se propone	Resolución
1	Historial de internación previa	Variables de hospitalización previa en 12 meses y días desde el último egreso.	
2	Variables condicionales (servicio/especialidad)	Evaluar si registran gravedad basal o capacidad/proceso hospitalario.	
5	Población de estudio	Restringir el alcance exclusivamente a adultos (>= 18 años).	
6	Volumen mínimo institucional	Umbral de 500 egresos y 10 muertes esperadas para publicación hospitalaria.	
10	Identificación visual de hospitales	Exhibición de nombres institucionales o anonimización en prototipo.	
11	Tratamiento de valores estructurados como RUT	Canalización de hallazgos de calidad hacia FONASA.	
12	Validación clínica de reglas	Mecanismo de gobernanza médica de las definiciones adoptadas.	
13	Rastreo de traslados salientes	Reconstrucción de trayectoria clínica longitudinal entre recintos.	
15	Estadías de cero días	Tratamiento de episodios ambulatorios en mortalidad.	
16	Exclusión de traslados entrantes	Tratamiento de pacientes recepcionados desde otros centros.	
17	Ventana de entrenamiento	Inclusión o exclusión de período pandémico COVID-19 (2020-2021).	

18. Glosario

Término	Definición
GRD (Grupos Relacionados por Diagnóstico)	Sistema que agrupa hospitalizaciones con características clínicas parecidas y consumo de recursos comparable.
Razón O/E	Cociente entre los eventos reales de un hospital y los que el modelo esperaba para sus pacientes. El valor 1,0 indica lo esperado.
Índice de Elixhauser	Medida estándar que resume las enfermedades previas de un paciente en 31 categorías de sí o no, sacadas de los diagnósticos secundarios.

Término	Definición
Score de van Walraven	Suma ponderada de las categorías de Elixhauser, donde cada una pesa según su relación histórica con la mortalidad.
Presente al ingreso (POA)	Marcador que indica si un diagnóstico ya existía al entrar al hospital. Los datos de FONASA no lo traen.
Dato censurado	Episodio cuyo resultado final se desconoce, que aquí son principalmente los traslados a otro hospital.
Fuga de información (data leakage)	Error que ocurre cuando el modelo usa información del futuro para predecir el presente. Hace que los resultados parezcan mejores de lo que son.
Partición temporal	División de los datos por período: los años antiguos entrenan y los recientes evalúan.
Calibración	Qué tan parecidas son las probabilidades que predice el modelo a la frecuencia real de los eventos.
Brier Score y Brier Skill Score	El Brier Score mide el error de las probabilidades. El Skill Score lo compara con un modelo que solo usa la prevalencia, y si es mayor que cero lo supera.
Pendiente de calibración	Número que indica si las probabilidades del modelo son demasiado extremas o demasiado tímidas. El valor ideal es 1.
PR AUC	Métrica que combina precisión y sensibilidad, útil cuando el evento es poco frecuente.
Gráfico de embudo (funnel plot)	Gráfico que muestra el O/E de cada hospital con límites de control que separan variaciones reales de las que explica el azar.
Sobredispersión	Situación en que los hospitales varían más entre sí de lo que explicaría el azar de muestreo.
Upcoding	Registrar más enfermedades o más graves de las reales, lo que sube el riesgo esperado y baja el O/E.
Alta anticipada	Dar de alta o trasladar a un paciente grave antes de que fallezca, de modo que la muerte no quede en las estadísticas del hospital.
Parquet	Formato de archivo por columnas, mucho más rápido de leer en análisis que el texto plano.
Arquitectura medallón	Organización de los datos en capas, de Cruda a Oro, donde cada una agrega calidad sobre la anterior.

22. Referencias

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

Cid, C., Dawson, N., Medina, C., Espinoza, A. y Bastías, G. (2024). Lecciones y desafíos del uso de los Grupos Relacionados por el Diagnóstico en Chile. Revista Panamericana de Salud Pública, 48, e67. doi: 10.26633/RPSP.2024.67

Congreso Nacional de Chile. (2008). Ley 20.285 sobre acceso a la información pública. https://www.bcn.cl/leychile/navegar?idNorma=276363

Elixhauser, A., Steiner, C., Harris, D. R. y Coffey, R. M. (1998). Comorbidity measures for use with administrative data. Medical Care, 36(1), 8-27.

Fung, C. H., Lim, Y.-W., Mattke, S., Damberg, C. y Shekelle, P. G. (2008). Systematic review: the evidence that publishing patient care performance data improves quality of care. Annals of Internal Medicine, 148(2), 111-123. doi: 10.7326/0003-4819-148-2-200801150-00006

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. y Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., ... Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. Nature Machine Intelligence, 2, 56-67. doi: 10.1038/s42256-019-0138-9

Moons, K. G. M., Altman, D. G., Reitsma, J. B., Ioannidis, J. P. A., Macaskill, P., Steyerberg, E. W., ... Collins, G. S. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): explanation and elaboration. Annals of Internal Medicine, 162(1), W1-W73. doi: 10.7326/M14-0698

Quan, H., Sundararajan, V., Halfon, P., Fong, A., Burnand, B., Luthi, J.-C., ... Ghali, W. A. (2005). Coding algorithms for defining comorbidities in ICD-9-CM and ICD-10 administrative data. Medical Care, 43(11), 1130-1139.

Schröer, C., Kruse, F. y Marx Gómez, J. (2021). A systematic literature review on applying CRISP-DM process model. Procedia Computer Science, 181, 526-534. doi: 10.1016/j.procs.2021.01.199

Shahian, D. M., Wolf, R. E., Iezzoni, L. I., Kirle, L. y Normand, S.-L. T. (2010). Variability in the measurement of hospital-wide mortality rates. New England Journal of Medicine, 363(26), 2530-2539. doi: 10.1056/NEJMsa1006396

Spiegelhalter, D. J. (2005). Funnel plots for comparing institutional performance. Statistics in Medicine, 24(8), 1185-1202. doi: 10.1002/sim.1970

Steyerberg, E. W., Vickers, A. J., Cook, N. R., Gerds, T., Gonen, M., Obuchowski, N., ... Kattan, M. W. (2010). Assessing the performance of prediction models: a framework for traditional and novel measures. Epidemiology, 21(1), 128. doi: 10.1097/EDE.0b013e3181c30fb2

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L. y Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. BMC Medicine, 17(1), 230. doi: 10.1186/s12916-019-1466-7

van Walraven, C., Austin, P. C., Jennings, A., Quan, H. y Forster, A. J. (2009). A modification of the Elixhauser comorbidity measures into a point system for hospital death using administrative data. Medical Care, 47(6), 626-633.