UNIVERSIDAD DE SANTIAGO DE CHILE · DEPARTAMENTO DE INGENIERÍA INFORMÁTICA

Fase 2: Comprensión de los datos

Análisis revisado a la luz de la Fase 1, explicado paso a paso

Proyecto: Modelo de aprendizaje automático para la comparación ajustada por riesgo del desempeño hospitalario en Chile

Estudiante Felipe Ignacio Baeza Muñoz
Profesor guía Manuel Villalobos Cid
Metodología CRISP-DM, fase 2 de 6
Fecha Octubre de 2026

Este documento reemplaza la lectura del informe «Informe_Fase2_Reestructurado». Se construyó a partir de las tablas que generó la suite de análisis (carpeta fase2_eda/salidas/extracto), contrastadas con las reglas y decisiones del informe de la Fase 1. Las cifras clave se verificaron de forma independiente leyendo los archivos.

Está escrito para alguien que recién se acerca al proyecto: cada concepto técnico se explica la primera vez que aparece.

Contenido

1. Lo esencial en una página 3

2. Conceptos que conviene tener claros 4

3. Cómo se conecta la Fase 2 con la Fase 1 4

4. Advertencia previa: se trabajó con un extracto 5

5. Recolección y descripción de los datos 6

6. Calidad de los datos 7

7. ¿Quiénes entran al análisis? La cohorte 8

8. Los desenlaces: mortalidad y estadía 9

9. Las enfermedades previas (Elixhauser) 12

10. ¿Qué variables pueden entrar al modelo? 14

11. Una primera mirada a los hospitales 17

12. Las 17 decisiones de la Fase 1, con la evidencia 18

13. Correcciones necesarias 20

14. Qué hacer antes de pasar a la Fase 3 21

Anexo A. Cómo se hizo esta revisión 21

Anexo B. Tablas de origen 22

1. Lo esencial en una página

La **Fase 2 de CRISP-DM** consiste en mirar los datos antes de construir cualquier modelo: qué contienen, qué tan limpios están y si confirman o contradicen lo que se supuso en la Fase 1. Esta revisión toma lo que la Fase 1 dejó planteado (8 reglas, 17 decisiones pendientes y varios supuestos) y lo contrasta con lo que efectivamente midió la suite de análisis.

5,2 %
de la base total se analizó (extracto de 49.999 egresos por año)

5,11 %
mortalidad en la cohorte del modelo (no 2,78 %)

+40 %
más diagnósticos registrados por paciente entre 2019 y 2024

72
hospitales distintos entre 2019 y 2024 (no 68)

Lo que salió bien

- La infraestructura es sólida: 1.747 pruebas automáticas, resultados idénticos al repetir la corrida y un «cortafuegos» que impidió mirar los desenlaces de 2024.
- Se confirmaron las reglas centrales de la Fase 1: el riesgo de mortalidad del GRD «conoce» el desenlace (R6), el diagnóstico principal no debe entrar a Elixhauser (R3) y la estadía de los fallecidos se comporta distinto (R8).
- Se encontró y corrigió un error real: el mapeo de comorbilidades con 3 caracteres hacía que la diabetes apareciera con 0 %.

Los cinco hallazgos que más pesan para lo que viene

1. Todo se midió sobre un **extracto**, no sobre los 5,8 millones de egresos. Las proporciones sirven; los conteos absolutos no.

2. El identificador de paciente **cambió de sistema entre 2020 y 2021**: ningún paciente de 2019–2020 se puede seguir en 2021–2024.

3. La **codificación crece cada año** (+40 %). Un modelo entrenado con años antiguos tenderá a sobreestimar el riesgo de los nuevos, y eso desplaza la razón O/E.

4. Varias variables que la Fase 1 dejó como permitidas o condicionales (especialidad, servicio de ingreso, tipo de ingreso, nivel de cuidado) **se parecen demasiado al hospital**.

5. Ninguna de las 17 decisiones está cerrada: la suite las deja todas «pendientes de decisión humana», aunque el informe de la Fase 1 marque varias como aprobadas.

Lo que hay que corregir en el informe actual de la Fase 2

Mezcla cifras del extracto con cifras de la base completa sin decirlo, muestra la mortalidad de 2024 (que el cortafuegos debía ocultar), calcula mal la cohorte de estadía, se declara «cerrada» con un criterio pendiente y contradice la arquitectura de la Fase 1. El detalle está en la sección 13.

2. Conceptos que conviene tener claros

Antes de entrar en los resultados, este glosario resume las ideas que aparecen una y otra vez. Si alguna palabra no se entiende más adelante, vuelve aquí.

Concepto	Qué significa, en simple
Egreso	Cada vez que un paciente sale del hospital (vivo o fallecido). Es la unidad de los datos: una fila = un egreso.
GRD	Grupos Relacionados por Diagnóstico. Sistema que clasifica cada egreso en un grupo de pacientes parecidos; en Chile se usa sobre todo para pagar a los hospitales.
Cohorte	El grupo de egresos que se decide analizar, después de sacar los que no corresponden (por ejemplo, recién nacidos sanos).
Desenlace	Lo que se quiere predecir: si el paciente falleció en el hospital y cuántos días estuvo hospitalizado.
Censurado	Egreso cuyo desenlace final no se conoce, por ejemplo un paciente trasladado a otro hospital: no sabemos si después sobrevivió.
Prevalencia	Qué porcentaje del grupo tiene una característica. «Mortalidad de 5 %» = 5 de cada 100 egresos fallecieron.
Intervalo de confianza (IC)	Rango donde probablemente está el valor real. Si dos intervalos no se tocan, la diferencia es muy probablemente real.
AUC	Mide qué tan bien una variable separa a quienes fallecen de quienes sobreviven. 0,5 = no sirve (como lanzar una moneda); 1,0 = separa perfecto.
Fuga de información	Usar como predictor algo que solo se conoce al final de la hospitalización. El modelo parece excelente, pero «hace trampa».
Proxy del hospital	Variable que, en la práctica, identifica qué hospital atendió al paciente. Si entra al modelo, el O/E deja de medir desempeño.
Razón O/E	Observado / Esperado. Muertes reales de un hospital divididas por las que el modelo esperaba según sus pacientes. 1,0 = dentro de lo esperado.
Extracto	Un subconjunto de los datos. Aquí: 49.999 egresos por año, no los ~1 millón por año de la base completa.
PSI	Índice que mide cuánto cambió la distribución de una variable entre dos períodos. Sobre 0,25 = cambio grande.
Elixhauser	Lista estándar de 31 enfermedades crónicas (diabetes, hipertensión, cáncer…) que se detectan en los diagnósticos secundarios para medir qué tan enfermo llegó el paciente.

3. Cómo se conecta la Fase 2 con la Fase 1

La Fase 1 (comprensión del dominio) definió **qué** se quiere hacer y **con qué reglas**. La Fase 2 (comprensión de los datos) revisa **si los datos permiten hacerlo así**. Por eso esta revisión no evalúa la Fase 2 por sí sola, sino como respuesta a lo que la Fase 1 dejó abierto.

Lo que dejó la Fase 1	Cómo lo trabaja la Fase 2	Dónde se ve aquí
8 reglas que no se pueden romper (R1–R8): nada que revele el desenlace, el hospital no es predictor, Elixhauser solo con diagnósticos secundarios, etc.	Se miden con datos: prueba de fuga, mapa de proxies, comparación con y sin diagnóstico principal.	Secciones 9 y 10

Lo que dejó la Fase 1	Cómo lo trabaja la Fase 2	Dónde se ve aquí
17 decisiones pendientes con el profesor guía (adultos, volumen mínimo, traslados, ventana de entrenamiento…).	Cada decisión tiene una o más hipótesis (26 en total) y un «semáforo» según la evidencia.	Sección 12
Supuestos sobre los datos (ID consistente, fechas, hospitales, códigos).	15 supuestos verificados: 6 aceptados, 6 rechazados, 3 no evaluables.	Secciones 5 y 6
Una cascada de exclusiones con volúmenes estimados.	La cascada se calcula de verdad y se comprueba que cuadra en cada año.	Sección 7
Una arquitectura por capas (Cruda → Bronce → Plata → Oro).	La suite lee los archivos sin modificarlos y deja un registro de cada acceso.	Sección 5

Idea clave

Cuando la Fase 2 contradice a la Fase 1, no es un error de la Fase 2: es justamente su trabajo. Lo que sí es un problema es que el informe de la Fase 1 diga «aprobado» en decisiones que los datos todavía no permiten cerrar.

4. Advertencia previa: se trabajó con un extracto

FONASA entregó cerca de 5,8 millones de egresos (2019–2024). Sin embargo, los archivos con que corrió la suite tienen **49.999 egresos por año**: 299.994 en total, alrededor del 5,2 % de la base. Los informes técnicos de la suite lo dicen explícitamente en cada página: el extracto «no es una muestra aleatoria simple: sirve para desarrollar y probar, no para conteos absolutos».

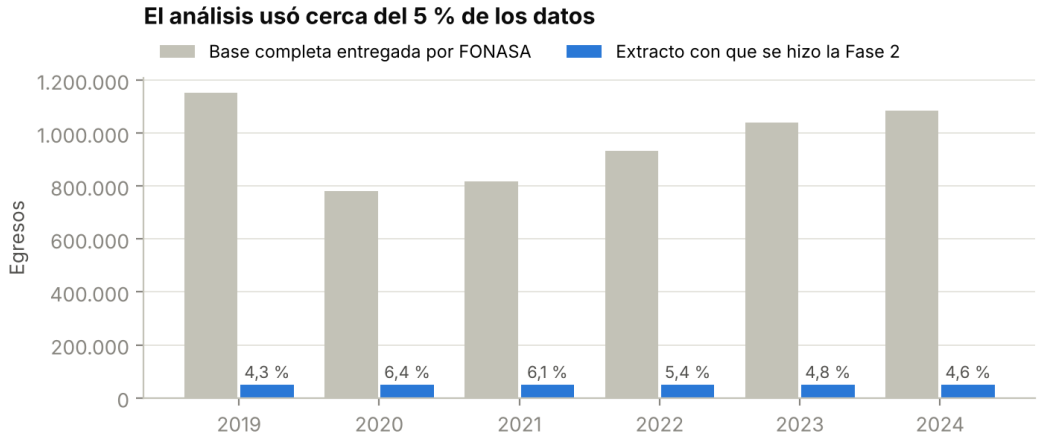


Figura 1. *Tamaño de la base completa (según los conteos documentados) frente al extracto analizado. El porcentaje sobre cada barra azul es la fracción de cada año que se analizó. Fuente: t21_archivos.csv y ledger_cifras.csv.*

Sirve para…	No sirve para…
Probar que el código funciona (lectura, limpieza, cascada, cortafuegos).	Decir cuántos egresos hay en cada cohorte de la base completa.
Estimar proporciones aproximadas: mortalidad, prevalencias, % de faltantes.	Medir el historial del paciente o enlazar traslados: el ingreso anterior casi nunca está en el mismo extracto.
Detectar problemas de formato y de calidad.	Decidir cuántos hospitales cumplen el volumen mínimo (cada hospital aparece con ~5 % de sus egresos).
Comparar variables entre sí (asociaciones, AUC).	Cerrar las decisiones 1, 6, 13 y 16.

Por qué importa

El informe actual de la Fase 2 presenta cifras como «Cohorte A: 4.269.412 egresos» que no salen de ninguna tabla de la suite (la suite midió 223.374 en el extracto). Toda cifra debe indicar si viene del extracto o de la base completa. El criterio DT12 («corrida con datos completos») sigue **pendiente**.

5. Recolección y descripción de los datos

5.1 Qué llegó

Seis archivos de texto (uno por año) con **129 columnas** separadas por «|». Todas las filas se leyeron y ninguna se rechazó. La lectura comprobó que filas leídas + filas rechazadas = líneas del archivo, tal como exige la capa Bronce de la Fase 1.

5.2 Problemas de formato encontrados

Problema	Años	Qué se hizo
Las fechas de 2023 vienen como DD-MM-AAAA; el resto como AAAA-MM-DD.	2023	El lector acepta ambos formatos.
El peso GRD usa coma decimal y a veces sin cero inicial («,4567»).	2020, 2021	Se convierte coma a punto.
Marca invisible (BOM) al inicio del archivo.	2021–2023	El lector la retira.
La columna del paciente se llama **ID_BENEFICIARIO en 2024** (no en 2019, como decía la Fase 1).	2024	Se lee por posición. Hay que corregir la Fase 1.
Texto «centinela» (p. ej. DESCONOCIDO) en el identificador.	Todos	Se cuenta como faltante «disfrazado».
Dos etiquetas de tipo de alta llegan cortadas («…HOGAR DE»).	Todos	Se asignan por el comienzo del texto; si no, se perdería el 0,72 % de los egresos.

5.3 Faltantes y valores raros

- **5 columnas** están vacías en todos los años y **62** traen valores centinela que el diccionario no cuenta como faltantes.
- Al comparar el diccionario de datos con lo medido: 53 columnas coinciden, 65 difieren y 11 no se pueden evaluar. La mayoría de las diferencias son pequeñas; **17** difieren en 0,5 puntos o más (sobre todo procedimientos y el bloque de recién nacidos). El informe actual marca esto como «PASS» sin explicarlo: conviene aclarar que «conciliado» significa «revisado», no «idéntico».
- Las columnas RN2ESTADO a RN4ESTADO son casi constantes (99,3 % a 100 % el mismo valor): relleno, no información clínica.

6. Calidad de los datos

6.1 Reglas de calidad

Se evaluaron 32 reglas (fechas imposibles, edades negativas, duplicados, códigos fuera de catálogo, etc.). La gran mayoría tiene **cero o menos de 10 casos**. Lo más llamativo: 1,42 % de los egresos tiene año de ingreso distinto al año del archivo (pacientes que ingresaron en diciembre y salieron en enero; es esperable) y 472 egresos de 2024 vienen de un hospital que no está en el catálogo. Los códigos CIE-10 del diagnóstico principal son válidos en el 99,9993 % de los casos.

> **Sobre el supuesto S03**
>
> El criterio fijado era «100 % de códigos válidos, sin tolerancia», así que formalmente el supuesto se rechaza aunque el resultado sea excelente. Lo correcto es decirlo así y explicar qué se hace con los pocos códigos inválidos (anularlos, según la regla R5), no reinterpretar el criterio después.

6.2 El identificador del paciente: el hallazgo más importante de calidad

La Fase 1 quería usar el identificador encriptado (CIP) para dos cosas: calcular el historial de hospitalizaciones del paciente y rastrear los traslados a otros hospitales. Para eso el identificador debe ser el mismo para la misma persona en todos los años. La suite midió cuántos identificadores aparecen en dos años distintos:

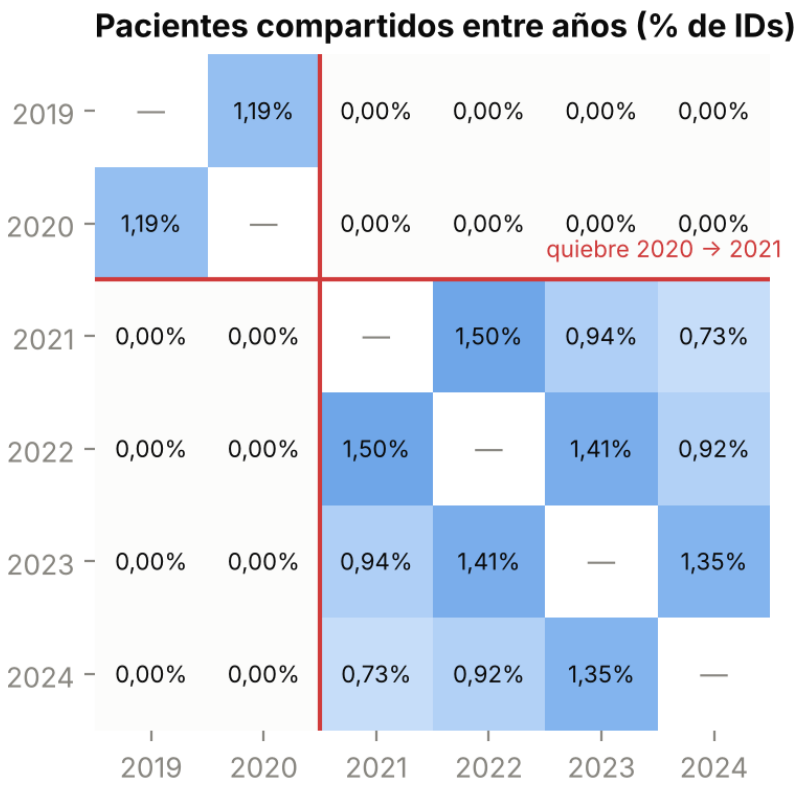


Figura 2. *Porcentaje de identificadores compartidos entre cada par de años. Entre 2019–2020 y 2021–2024 no hay ningún paciente en común: el sistema de encriptación cambió. Fuente: t24_id_traslape.csv (verificado leyendo los archivos).*

Hay **dos «mundos» de identificadores**: 2019–2020 y 2021–2024. Un paciente de 2020 no se puede reconocer en 2021. Esto pesa más que el 1,82 % de identificadores con fecha de nacimiento inconsistente que el informe actual usa como único motivo para descartar el historial. Además, dentro de cada mundo la inconsistencia es

1,54 % (2019–2020) y 1,95 % (2021–2024), medida en un extracto.

> **Qué significa para la Fase 1**
>
> • **Decisión 1 (historial):** la Fase 1 v2 la marca «descartada». Con los datos completos, el historial sí podría calcularse dentro de 2021–2024 (para egresos de 2022 en adelante), pero no para 2019–2021. La decisión debe tomarse sabiendo esto, no por el 1,82 %.
>
> • **Decisión 13 (rastreo de traslados):** igual: es imposible entre 2020 y 2021, y no evaluable en el extracto.
>
> • **Decisión 17 (ventana de entrenamiento):** el quiebre del ID es una de las razones por las que la evidencia sugiere 2020–2022 o separar 2019.

6.3 Hospitales

Aparecen **72 códigos de hospital distintos** entre 2019 y 2024: 65 por año en 2019–2022, 68 en 2023 y 72 en 2024 (uno fuera del catálogo). La Fase 1 decía 68. Tres hospitales son pediátricos o monográficos y quedarían fuera si se analizan solo adultos. El catálogo disponible no trae el nivel de complejidad, que la Fase 1 necesitaba para los filtros de la plataforma.

7. ¿Quiénes entran al análisis? La cohorte

No todos los egresos sirven para comparar hospitales. La Fase 1 (sección 9) definió qué sacar y por qué. La suite aplicó esos filtros en orden, como una cascada, y comprobó que en cada año los egresos que quedan más los excluidos suman el total.

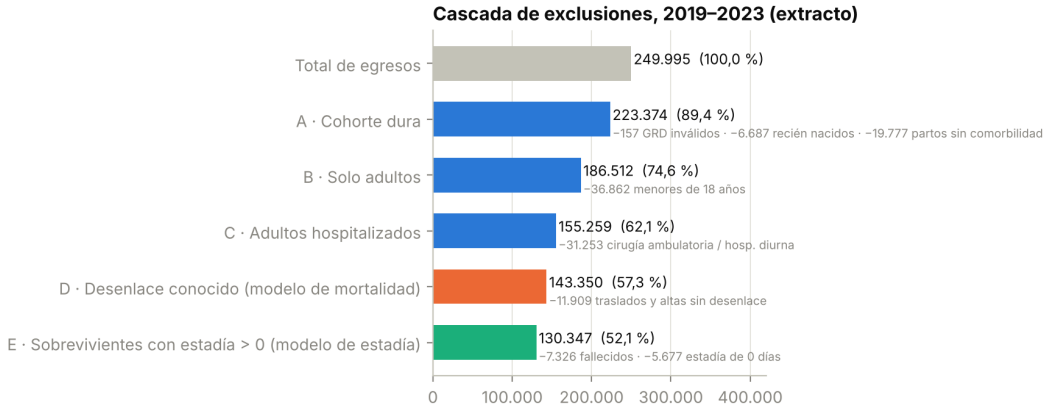


Figura 3. *Cascada de exclusiones 2019–2023 en el extracto. Cada barra es lo que queda después del filtro; debajo se indica qué se sacó. D es la base del modelo de mortalidad y E la del modelo de estadía. Fuente: t23_cascada.csv.*

Paso	Por qué se excluye (Fase 1)	Lo que dicen los datos
GRD inválidos, recién nacidos sanos, partos sin complicación	No son hospitalizaciones agudas comparables; distorsionarían a las maternidades.	10,7 % del total. La cohorte A no depende de quién falleció.
Menores de 18 años	La mortalidad infantil tiene otra lógica (decisión 5).	La mortalidad sube de 3,41 % a 4,02 %.
Actividad ambulatoria	Cirugía mayor ambulatoria y hospitalización diurna casi no tienen muertes (decisión 15).	Su mortalidad es 0,11 veces la del resto: diluiría el O/E.
Traslados y altas sin desenlace	No se sabe si el paciente sobrevivió (censurados).	11.909 egresos (4,8 %).
Fallecidos y estadías de 0 días	Solo para el modelo de estadía (regla R8).	7.326 fallecidos y 5.677 sobrevivientes con 0 días.

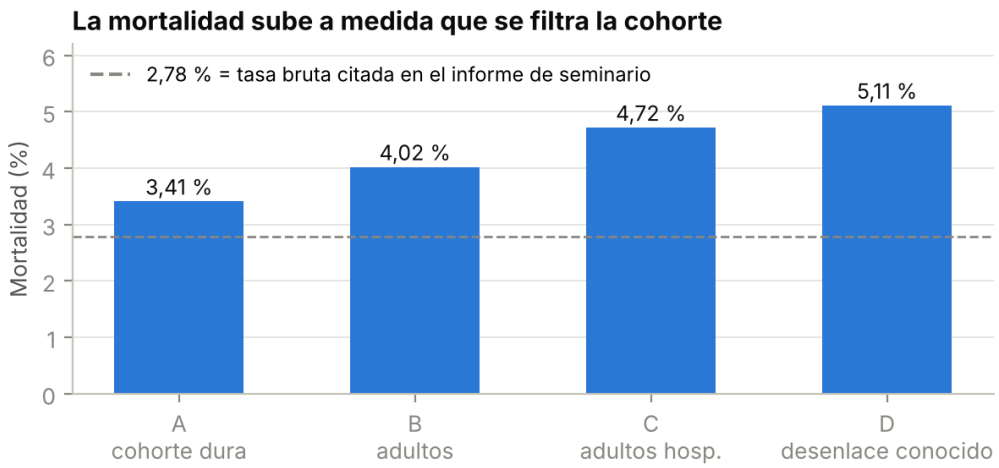


Figura 4. Mortalidad en cada variante de cohorte (2019–2023, extracto). Cada filtro saca grupos de bajo riesgo, así que la mortalidad sube. La línea punteada es la tasa que cita el informe de seminario. Fuente: t23_cascada_variantes.csv.

Consecuencia práctica

La línea base para evaluar el modelo de mortalidad (PR AUC) debe ser la prevalencia de la cohorte D, **alrededor de 5,1 %**, y no el 2,78 % del informe de seminario. Hay que recalcularla con los datos completos y, sobre todo, en el año de prueba (en 2023 la cohorte D tiene 4,08 %).

Error en el informe actual

El informe dice que la cohorte E (estadía) es D menos los fallecidos. En realidad también se sacan los sobrevivientes con estadía de 0 días (5.677 en el extracto, el paso EX08). En el informe, E = D × (1 − 0,0511) exactamente, lo que delata que ese paso se omitió.

8. Los desenlaces: mortalidad y estadía

8.1 Tipos de alta

Cada tipo de alta tiene un «rol» definido en la Fase 1: evento (falleció), no evento (sobrevivió) o censurado (no se sabe).

Tipo de alta	Rol	Egresos	%
Domicilio	Sobrevivió	224.254	89,7 %
Fallecido	**Evento**	7.748	3,1 %
Hospitalización domiciliaria	Censurado	5.520	2,2 %
Derivación a otro hospital del servicio	Censurado	4.910	2,0 %
Alta voluntaria	Sobrevivió	2.681	1,1 %
Derivación a otro hospital de la red nacional	Censurado	1.888	0,8 %
Derivación a otros centros (cárcel, hogar)	Censurado	1.018	0,4 %
Fuga del paciente	Sobrevivió	862	0,3 %
Derivación a institución privada (compra / voluntario)	Censurado	1.109	0,4 %

8.2 Mortalidad a lo largo del tiempo

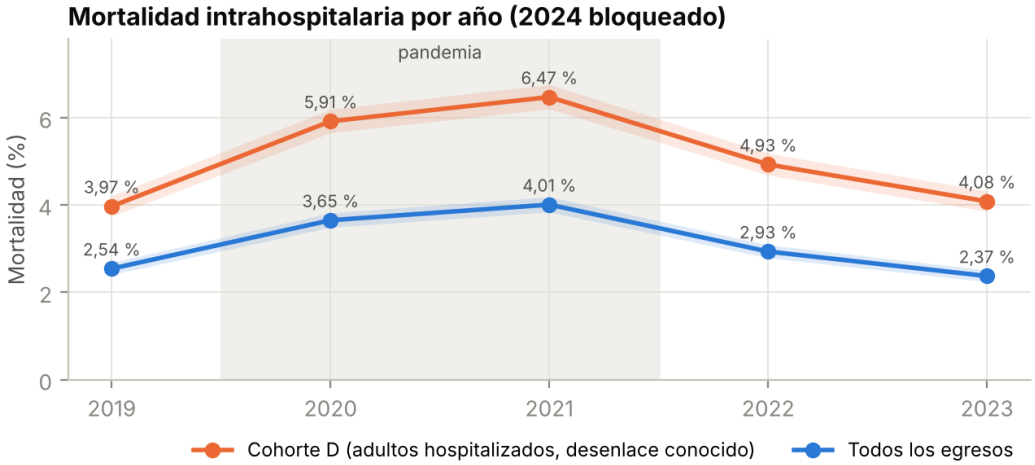


Figura 5. *Mortalidad por año con su intervalo de confianza (banda). 2020 y 2021 suben claramente por la pandemia. 2024 no se muestra porque el cortafuegos impide leerlo. Fuente: t23_resultado_anio.csv (verificado leyendo los archivos).*

La mortalidad de 2020–2022 es **1,39 veces** la de 2019. Esto respalda la decisión 17 de la Fase 1: hacer un análisis de sensibilidad sin 2020–2021. Ojo: el informe actual muestra una mortalidad de 2024 (2,46 %) y valores por año distintos a estos (2,57 % en vez de 2,54 % en 2019, por ejemplo). Esa tabla no proviene de la suite y viola el cortafuegos que el mismo informe dice haber respetado.

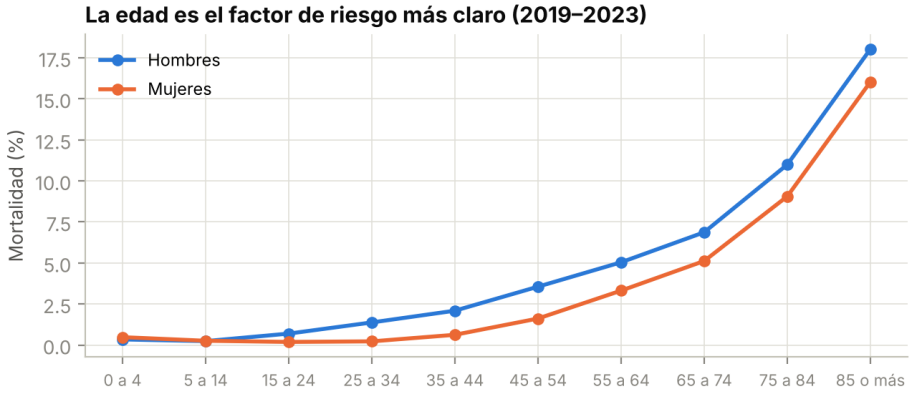


Figura 6. *Mortalidad por grupo de edad y sexo (2019–2023, todos los egresos del extracto). El riesgo se multiplica con la edad y es mayor en hombres en casi todos los tramos. Fuente: t23_resultado_edad_sexo.csv.*

8.3 Pacientes que llegan trasladados

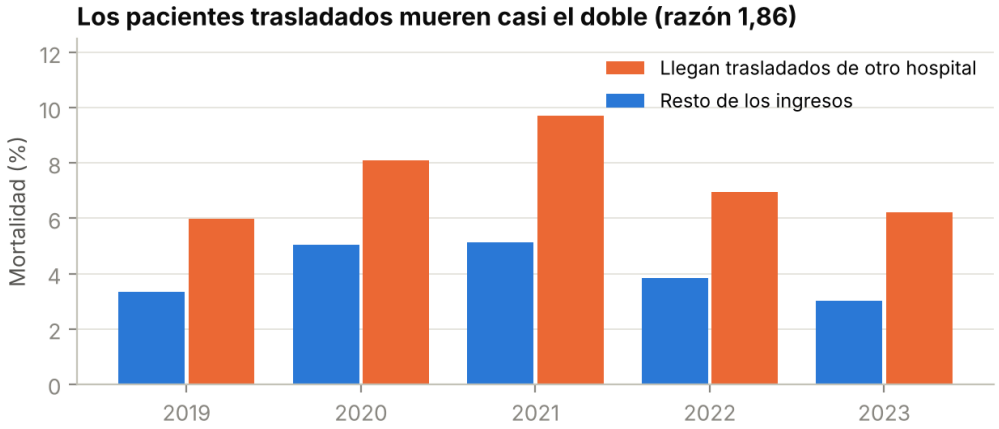


Figura 7. *Mortalidad de quienes llegan desde otro hospital de la red frente al resto. Son casi el doble de graves. Fuente: t23_resultado_entrantes.csv.*

La Fase 1 decidió excluir a los traslados entrantes del modelo y del O/E (decisión 16). La evidencia muestra que son pacientes más graves (razón 1,86). Excluirlos evita contar dos veces a la misma persona, pero también saca justamente los casos complejos que reciben los hospitales de referencia. Conviene declararlo como limitación y revisar el efecto con los datos completos. Además, el campo HOSPPROCEDENCIA no sirve para identificarlos: en 30,6 % de los casos apunta al mismo hospital. Debe usarse TIPO_PROCEDENCIA.

8.4 Días de estadía



Figura 8. *Distribución de la estadía de los sobrevivientes (2019–2022). El eje vertical es logarítmico: cada marca es 10 veces la anterior. La mayoría se va en pocos días, pero hay casos de cientos de días. Fuente: t23_estancia_hist.csv.*

- La mediana es 4 días y la media 7,4: la media sube por los casos muy largos (el máximo fue 2.211 días, probablemente un error de registro).
- La varianza es 22,5 veces la media (lo esperable en una distribución Poisson sería 1). Esto apoya usar un objetivo **Tweedie** en vez de Poisson puro (decisión 9).
- La regla de corte en el percentil 99 (**51 días**) afecta solo al 0,97 % de los sobrevivientes y se confirma en 2023 (0,78 %). Se recomienda adoptarla (decisión 7), aplicándola igual a los días observados y a los esperados para no sesgar el O/E.

Sobre las estadías de 0 días: 75,7 % son de actividad ambulatoria. En hospitalización tradicional, su mortalidad es 0,32 veces la del resto, sobre el umbral de 0,25, así que conviene mantenerlas en el modelo de mortalidad, como propuso la Fase 1 (decisión 15).

9. Las enfermedades previas (Elixhauser)

La regla R3 de la Fase 1 dice que el ajuste por riesgo se basa en 31 enfermedades crónicas detectadas en los diagnósticos secundarios. Es la parte más importante del ajuste: sin ella, los hospitales que atienden pacientes más enfermos parecerían peores.

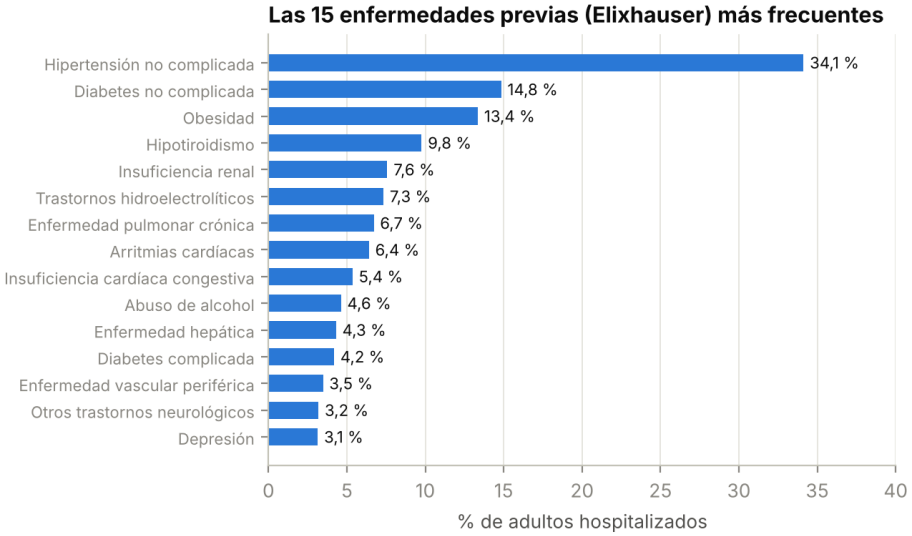


Figura 9. *Las 15 categorías de Elixhauser más frecuentes en adultos hospitalizados (2019–2024). Fuente: t23_elix_prevalencia.csv.*

9.1 Un error que se detectó y corrigió

Una versión anterior del código comparaba solo los primeros 3 caracteres de cada código CIE-10. Pero algunas enfermedades se definen con 4 caracteres: por ejemplo, la diabetes «complicada» y «no complicada» comparten las mismas tres primeras letras (E10–E14) y se distinguen por el cuarto. Resultado: la diabetes desaparecía.

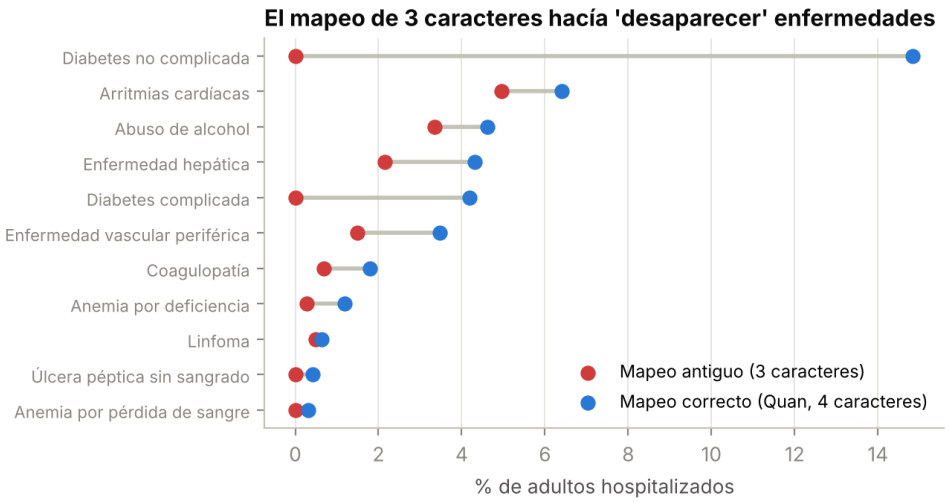


Figura 10. *Las 11 categorías que cambian más de 20 % entre el mapeo antiguo (rojo) y el correcto (azul). Fuente: t23_elix_vs_3c.csv.*

9.2 Confirmación de la regla R3

Si se incluyera el diagnóstico principal en Elixhauser, el «tumor sólido» pasaría de 3,1 % a 6,4 % de los pacientes (+110 %): el motivo de ingreso se confundiría con una enfermedad previa. La regla R3 queda respaldada.

9.3 La codificación aumenta cada año

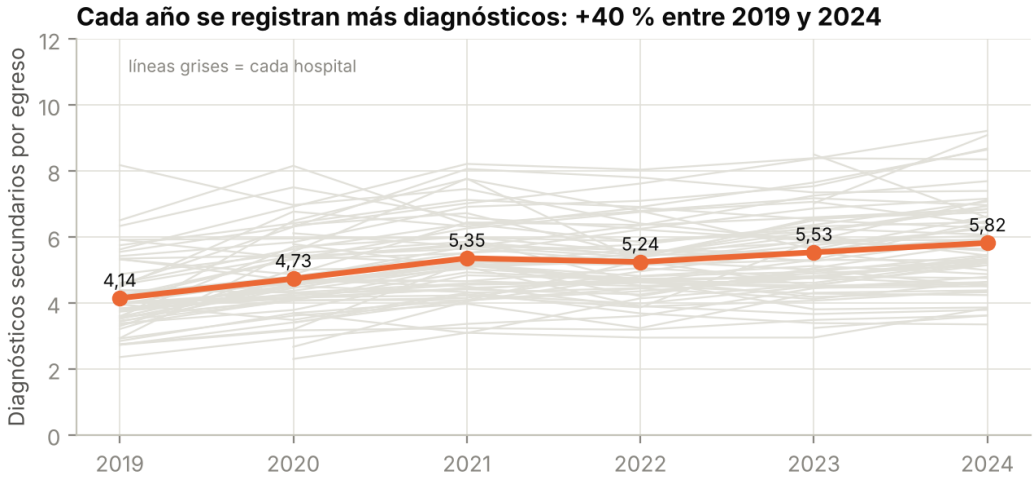


Figura 11. *Promedio de diagnósticos secundarios por egreso de adultos hospitalizados (naranjo) y la trayectoria de cada hospital (gris). Fuente: t23_deriva_codificacion.csv (verificado leyendo los archivos 2019–2023).*

En 2019 se registraban 4,14 diagnósticos secundarios por paciente; en 2024, 5,82 (+40 %). Y no crece igual en todos los hospitales: entre los que tienen suficientes datos, el aumento va de 8 % a 79 %.

Por qué es un riesgo serio para el indicador

Si un hospital registra más diagnósticos, su riesgo «esperado» sube y su O/E baja, aunque los pacientes sean iguales. Un modelo entrenado con 2019–2022 verá en 2024 pacientes que «parecen» más enfermos.

Consecuencias: (1) el O/E global de 2024 podría quedar bajo 0,95 por la codificación y no por el modelo; (2) los hospitales que más mejoraron su registro saldrían favorecidos.

Qué hacer: recalibrar con 2023 (ya está en el plan), revisar la prevalencia de cada categoría por año antes de entrenar, mostrar el índice de exhaustividad junto al O/E y agregar este riesgo a la tabla de riesgos de la Fase 1, que hoy no lo tiene.

10. ¿Qué variables pueden entrar al modelo?

La suite analizó 58 variables candidatas con tres preguntas: ¿predice la mortalidad?, ¿describe al paciente o al hospital?, ¿se conoce al momento del ingreso?

10.1 Qué tanto predice cada variable

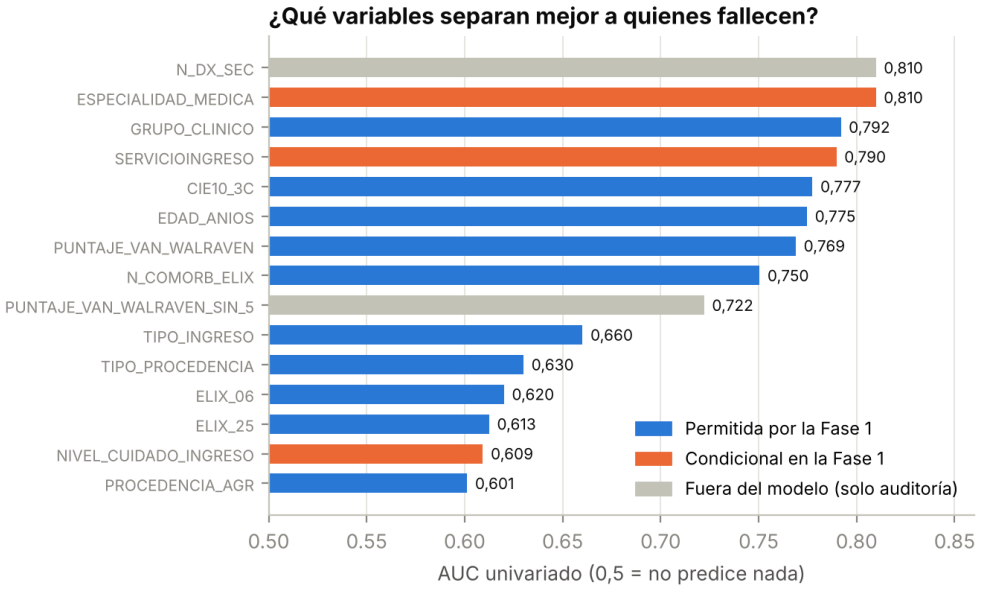


Figura 12. *Las 15 variables que mejor separan a fallecidos de sobrevivientes por sí solas (AUC, 2019–2022). El color indica qué decidió la Fase 1 sobre cada una. Fuente: t23_ranking_variables.csv.*

La variable que más predice es el **número de diagnósticos secundarios** (N_DX_SEC), justamente la que crece con la codificación y que la Fase 1 dejó fuera del modelo (solo para el índice de exhaustividad). La evidencia respalda esa decisión: predice en parte porque refleja cómo codifica cada hospital.

10.2 ¿Describe al paciente o al hospital?

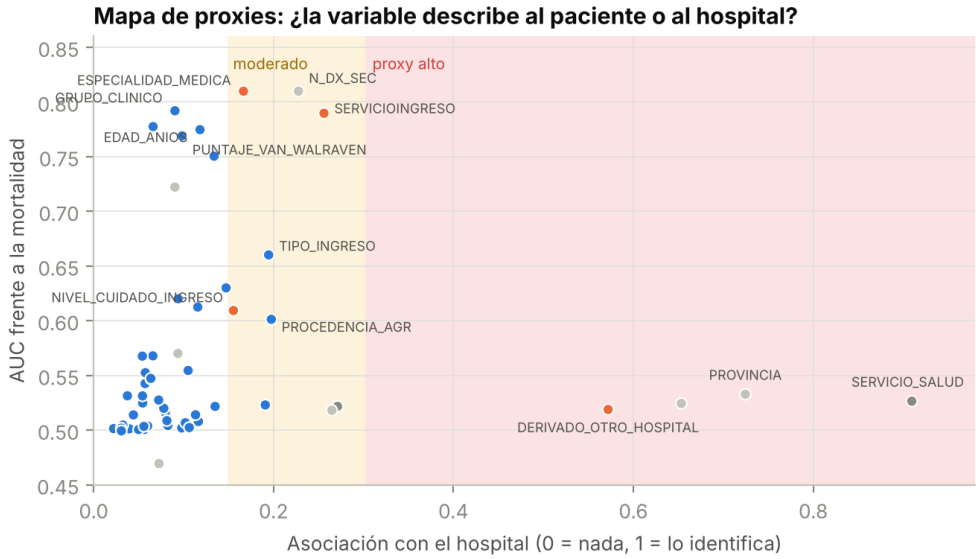


Figura 13. *Cada punto es una variable. Hacia la derecha, más se parece al hospital; hacia arriba, más predice la mortalidad. Lo ideal está arriba a la izquierda. Fuente: t23_proxy_hospital.csv.*

La regla R2 de la Fase 1 prohíbe usar al hospital como predictor. Varias variables quedan en la zona de riesgo:

Variable	Fase 1 la dejó como…	Asociación con el hospital	Recomendación
ESPECIALIDAD_MEDICA	Condicional	0,17 (moderada); 12 especialidades existen en un solo hospital	Fuera del modelo principal; probar en sensibilidad.
SERVICIOINGRESO	Condicional	0,26 (moderada)	Registra el ingreso (no la estadía), pero refleja la estructura del hospital. Sensibilidad.
NIVEL_CUIDADO_INGRESO	Condicional	0,16; idéntica a SERVICIOINGRESO	Redundante con la anterior: elegir una o ninguna.
TIPO_INGRESO (urgencia / programado)	Permitida	0,19 (moderada)	Mantener: es un factor de riesgo clásico. Vigilar en la Fase 3.
DERIVADO_OTRO_HOSPITAL	Condicional	0,57 (alta)	Excluir (R2).
PROVINCIA, COMUNA, SERVICIO_SALUD	Fuera del modelo	0,65 a 0,91 (alta)	Mantener fuera; confirma la decisión 3.

10.3 Prueba de fuga

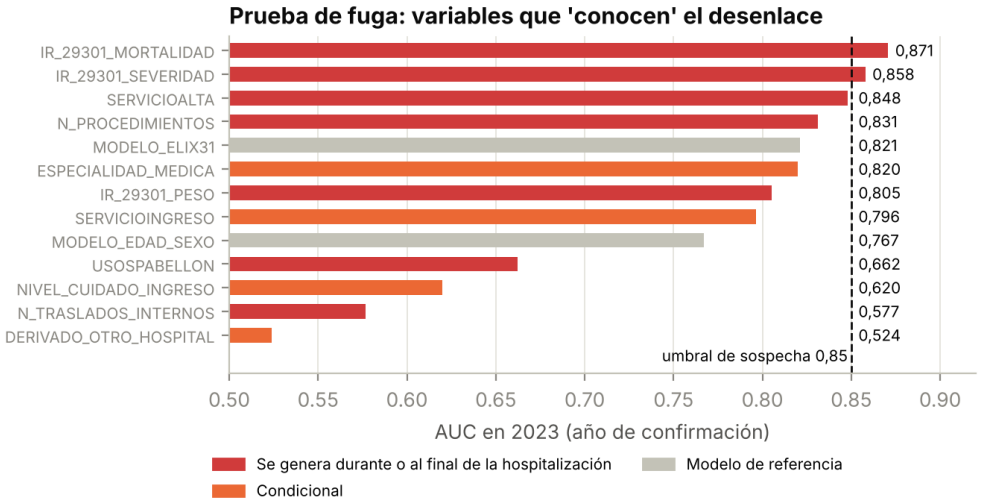


Figura 14. *AUC en 2023 de las variables que se generan durante o al final de la hospitalización (rojo) y de las condicionales (naranjo), frente a dos modelos de referencia (gris). Fuente: t23_fuga.csv.*

- El **riesgo de mortalidad del GRD** (0,871) y la **severidad del GRD** (0,858) superan el umbral: «conocen» el desenlace porque se calculan al alta. Confirma la regla R6 y la decisión 14.
- Matiz: la severidad dio 0,842 en 2019–2022 (bajo el umbral) y solo lo supera en 2023. El argumento fuerte no es el número sino que se calcula con información del alta. El informe actual habla de «demostración matemática»; es más preciso decir «evidencia que respalda la exclusión».
- Un modelo exploratorio (regresión L1) llegó a AUC 0,925, pero apoyado en las variables cercanas al hospital. **No es una meta realista** y no debe citarse como tal. Como referencia honesta: edad y sexo solos dan 0,767; las 31 categorías de Elixhauser solas, 0,821.

> **Colinealidad**
> El número de comorbilidades y el puntaje de van Walraven son sumas de las 31 categorías. Si entran juntos al mismo modelo, la información se repite exactamente. Se usan solo en la línea base simple. La tabla 5.3 de la Fase 1 todavía lista van Walraven como predictor «permitido con reserva»: hay que actualizarla.

11. Una primera mirada a los hospitales

El indicador final será un **gráfico de embudo**: cada hospital es un punto según su tamaño (eje horizontal) y su resultado (eje vertical). Las curvas marcan hasta dónde puede llegar un hospital solo por azar: los hospitales chicos tienen más variación natural, por eso el embudo es más ancho a la izquierda. Un punto fuera de las curvas es una señal para revisar, no un veredicto.

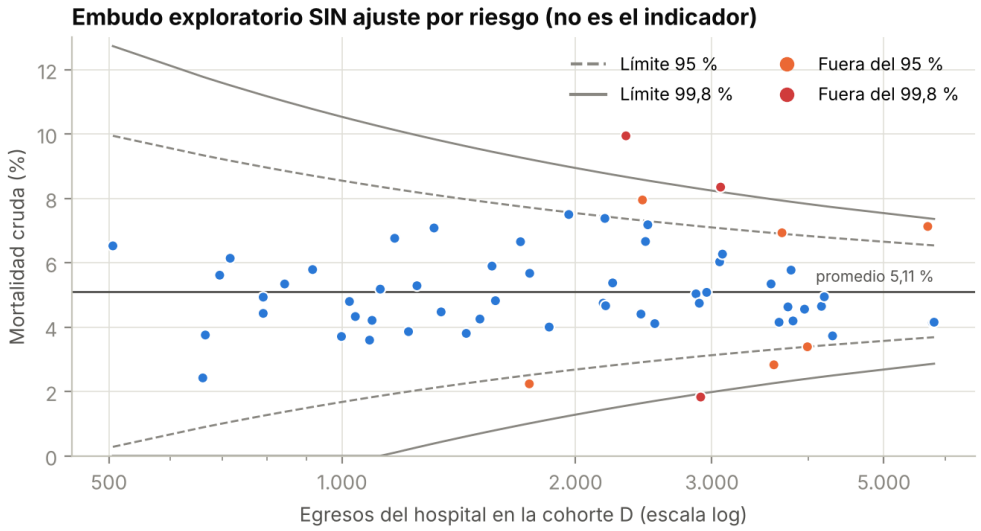


Figura 15. *Embudo exploratorio de la mortalidad* ***cruda*** *(sin ajuste por riesgo) por hospital, 2019–2023, extracto. Solo se muestran hospitales con al menos 300 egresos. Los límites ya incluyen la corrección de sobredispersión. Fuente: t23_embudo.csv.*

- Aun en datos crudos, la variación entre hospitales es **6,3 veces** mayor que la que explicaría el azar. Esto confirma que la corrección de Spiegelhalter que planteó la Fase 1 es indispensable: sin ella casi todos los hospitales quedarían marcados.
- De 66 hospitales evaluables, 9 quedan fuera del límite de 95 % y 3 fuera del de 99,8 %. **No significa nada todavía**: falta el ajuste por riesgo, que es todo el propósito del proyecto.
- Volumen mínimo (decisión 6): con el extracto solo 23 de 67 hospitales cumplen «500 egresos y 10 muertes esperadas», pero en la base completa cada hospital tiene unas 20 veces más egresos. No es evaluable hasta correr con los datos completos.

12. Las 17 decisiones de la Fase 1, con la evidencia

El semáforo es el de la suite: **verde** = la evidencia respalda la propuesta; **amarillo** = la respalda con matices; **gris** = no se puede decidir con datos (por el extracto o porque es institucional). Ninguna quedó en rojo. La columna «Recomendación» es la lectura de esta revisión; la decisión final es del estudiante y el profesor guía.

N.°	Tema	Semáforo	Qué dicen los datos	Recomendación
1	Historial del paciente	● Gris	ID cambia entre 2020 y 2021; no evaluable en el extracto.	No darlo por descartado: evaluarlo en 2021–2024 con datos completos o declarar por qué no se usa.
2	Servicio de ingreso, especialidad, derivado	● Amarillo	Registran el ingreso, pero con asociación moderada a alta con el hospital.	Fuera del modelo principal; sensibilidad aparte.
3	Variables de equidad fuera del modelo	● Verde	Provincia y comuna identifican al hospital (0,65–0,73).	Mantener fuera.
4	Etnia	● Gris	Codificación muy inestable entre años (PSI hasta 17,9).	Mantener fuera; solo describir.
5	Solo adultos (≥ 18)	● Amarillo	Cambia la mortalidad 0,67 puntos; deja fuera 3 hospitales pediátricos.	Adoptar y declarar los hospitales excluidos.
6	Volumen mínimo 500 / 10	● Gris	No evaluable en extracto.	Mantener la propuesta y medir con datos completos.

N.°	Tema	Semáforo	Qué dicen los datos	Recomendación
7	Corte de estadías largas	● Verde	p99 = 51 días; afecta 0,97 % y se confirma en 2023.	Adoptar, igual en observados y esperados.
8	Sensibilidad sin 5 categorías	● Amarillo	Las 5 más sospechosas medidas coinciden solo 3 con la lista de la Fase 1.	Fijar una sola lista con revisión clínica.
9	Meta O/E de estadía 0,95–1,05	● Amarillo	Estadía muy dispersa (índice 22,5).	Usar Tweedie; mantener la meta.
10	Nombres de hospitales	● Gris	Decisión institucional.	Usar códigos hasta que FONASA responda.
11	Aviso a FONASA por RUT	● Amarillo	0 valores con forma de RUT en el extracto.	Repetir la búsqueda con datos completos.
12	Revisión clínica	● Gris	Decisión institucional.	Buscar una contraparte clínica antes de la Fase 3.
13	Rastreo de traslados	● Gris	Imposible entre 2020 y 2021; no evaluable en extracto.	Mantener censurados; declarar la limitación.
14	Severidad GRD solo en sensibilidad	● Verde	AUC 0,858 en 2023, sobre el umbral.	Adoptar.
15	Estadía 0 y actividad ambulatoria	● Amarillo	Ambulatoria: mortalidad 0,11 veces la del resto; estadía 0: 0,32.	Sacar la ambulatoria; conservar estadía 0 en mortalidad.
16	Traslados entrantes	● Gris	Mueren 1,86 veces más; HOSPPROCEDENCIA no sirve.	Definirlos con TIPO_PROCEDENCIA y medir el efecto de excluirlos.
17	Ventana de entrenamiento	● Amarillo	Pandemia, quiebre del ID y deriva de codificación.	Mantener 2019–2022 con sensibilidades (sin 2020–21 y sin 2019) y recalibrar con 2023.

> **Diferencia con el informe de la Fase 1**
>
> El informe de la Fase 1 v2 marca como «Aprobado» las decisiones 5, 15, 16 y 17 y como «Descartado» la 1 y la 13. La suite deja las 17 «pendientes de decisión humana». Si el profesor guía ya las aprobó, hay que dejar constancia (fecha y forma). Si no, el texto debe decir «propuesta». Además, la tabla de la Fase 1 solo muestra 11 de las 17 decisiones (faltan 3, 4, 7, 8, 9 y 14).

13. Correcciones necesarias

13.1 En el informe de la Fase 1

Dónde	Dice	Debería decir
Sección 4 y 7	El ID se llamaba ID_BENEFICIARIO en 2019.	Se llama ID_BENEFICIARIO en **2024**; además, el sistema de ID cambia entre 2020 y 2021.
Sección 9.1	68 hospitales.	72 códigos distintos entre 2019 y 2024 (68 en 2023).
Sección 9.3	Volúmenes «proyectados» desde la muestra.	Indicar que vienen del extracto y reemplazarlos al correr la base completa.
Sección 9.5	Prevalencias de cohortes A–D.	Correctas, pero aclarar que son del extracto 2019–2023 y que en 2023 la cohorte D baja a 4,08 %.
Secciones 5.1 y 16	«Las cinco categorías» de la sensibilidad, sin nombrarlas.	Nombrarlas. La medición propone: pérdida de peso, circulación pulmonar, trastornos hidroelectrolíticos, psicosis y anemia por deficiencia.
Tabla 5.3 y sección 7	Van Walraven como predictor; historial «pendiente».	Van Walraven solo en la línea base; historial con el estado real de la decisión 1.
Sección 16 (riesgos)	—	Agregar: deriva de codificación y quiebre del identificador.
Referencias internas	R5 → «10.3»; volumen → «11.3»; decisiones → «sección 20».	R5 → sección de modelado; volumen → 11.2; decisiones → 19.

13.2 En el informe actual de la Fase 2

Problema	Por qué importa	Cómo corregirlo
Presenta conteos de millones (cohorte A 4.269.412, E 2.701.129…) que la suite no calculó.	Parecen medidos sobre la base completa, pero el DT12 está pendiente.	Usar las cifras del extracto (A = 223.374) rotuladas como tal, o esperar la corrida completa.
Tabla anual con mortalidad 2024 = 2,46 %.	Contradice el cortafuegos (DT03) y la regla R7.	Quitar la columna de 2024 o explicar su origen.
Mortalidad por año distinta a la de la suite (2,57 % vs 2,54 % en 2019, etc.).	Cifras sin respaldo en ninguna tabla.	Usar t23_resultado_anio.csv.
Cohorte E = D menos fallecidos.	Omite 5.677 estadías de 0 días (EX08).	Agregar el paso EX08.
«Fase 2 verificada y cerrada».	DT12 pendiente: 9 hipótesis y 80 cifras no verificables.	«Cerrada sobre el extracto; pendiente la corrida completa».
S01 como único motivo para descartar el historial.	Omite el quiebre del ID 2020→2021, que es más grave.	Agregar la figura de traslape y los dos regímenes.
«La Fase 3 ejecutará las transformaciones sobre PostgreSQL».	La Fase 1 dice que PostgreSQL no guarda registros de pacientes.	Las transformaciones van en Parquet (capas Plata y Oro).
«Demostración matemática» de fuga.	La severidad no supera el umbral en 2019–2022.	Hablar de evidencia y del argumento conceptual.
No incluye figuras ni las tablas de calidad.	Se generaron 33 figuras y 97 tablas.	Incluir al menos las de este documento.

14. Qué hacer antes de pasar a la Fase 3

#	Tarea	Por qué
1	Correr la suite con la **base completa** (run_fase2_eda.py con la fuente completa).	Cierra el DT12 y las 9 hipótesis no evaluables.
2	Reunión con el profesor guía para cerrar las 17 decisiones y dejar registro.	Hoy todas están pendientes según la suite.
3	Decidir variable por variable el destino de especialidad, servicio y nivel de cuidado.	Es la decisión que más cambia el modelo.
4	Actualizar la Fase 1 con las correcciones de la sección 13.1.	Que ambos informes cuenten la misma historia.
5	Reescribir el informe de la Fase 2 con cifras rotuladas y figuras.	Sección 13.2.
6	Agregar la deriva de codificación y el quiebre del ID a los riesgos, con plan.	Afecta la calibración y la decisión 17.
7	Fijar la lista de 5 categorías de Elixhauser con revisión clínica.	Decisiones 8 y 12.
8	Pedir a FONASA la respuesta formal por los microdatos y las condiciones de publicación.	Falta en el expediente (decisión 10).

Anexo A. Cómo se hizo esta revisión

- Se leyeron los informes del seminario, de la Fase 1 (v2 corregida) y de la Fase 2 (reestructurado).
- Se leyeron los 7 informes técnicos y las tablas de la suite en fase2_eda/salidas/extracto (manifiesto de la corrida incluido).
- Se verificaron de forma independiente, leyendo los archivos de 2019 a 2023, la mortalidad por año, el promedio de diagnósticos secundarios y el traslape de identificadores: coinciden exactamente con la suite. **No se leyó el archivo de 2024**, para respetar el cortafuegos.
- Todos los gráficos se construyeron a partir de las tablas CSV de la suite; cada figura indica su tabla de origen.

Anexo B. Tablas de origen

Tema	Tablas (carpeta tablas/)
Volumen y archivos	t21_archivos.csv, ledger_cifras.csv
Formato y carga	t21_problemas_carga.csv, t21_deriva_formato.csv
Calidad e identificador	t24_reglas.csv, t24_id_traslape.csv, t24_id_consistencia.csv
Cohorte	t23_cascada.csv, t23_cascada_variantes.csv
Desenlaces	t23_tipoalta.csv, t23_resultado_anio.csv, t23_resultado_edad_sexo.csv, t23_resultado_entrantes.csv
Estadía	t23_estancia_hist.csv, t23_estancia_dispersion.csv, t23_cola_estancia.csv, t23_resultado_estratos.csv
Comorbilidad	t23_elix_prevalencia.csv, t23_elix_vs_3c.csv, t23_elix_principal.csv, t23_deriva_codificacion.csv
Variables	t23_ranking_variables.csv, t23_proxy_hospital.csv, t23_fuga.csv, t23_importancia.csv, t23_vif.csv
Hospitales	t23_hospitales_resumen.csv, t23_volumen_umbrales.csv, t23_embudo.csv
Decisiones y supuestos	decisiones_evidencia.csv, supuestos_verificados.csv, cambios_fase1.csv, cambios_fase2.csv, verificacion_dt.csv